Fantasy iGaming Data Department

The Ultimate Data Function Reference

Полный playbook по организации аналитической функции в iGaming-компании. Архитектура, метрики, процессы, команда, ML — всё в одном месте.

Константин Гупалов

2026

Disclaimer

Все данные, компании и структуры вымышлены. Fantasy iGaming LTD — вымышленная компания, созданная для демонстрации подходов к организации data-функции.

Это не best practice и не консалтинг. Это стартовая точка для обсуждения и обучения. Идеализированная, но реалистичная картина — reference, который может быть полезен при построении или реструктуризации data-функции.

Все числа (MAU, NGR, зарплаты, бюджеты) реалистичны для компании заявленного масштаба (~500K MAU, ~$5M NGR/мес, CIS primary market), но не являются данными реальной компании.

О компании

Продукт	Sportsbook + Casino
Рынки	CIS (primary), LatAm (growing), Europe (new)
MAU	~500K
NGR / мес.	~$5M
Команда	~300 чел.
Data Team	20 чел., 4 стрима
Стадия	Scale-up
Стек	ClickHouse, dbt, Airflow, Metabase

Оглавление

01. Data Architecture 9

02. Org Structure 15

- Org Chart 15
- Стримы 15
- RACI Matrix 18
- Skill Matrix 19
- Career Ladder 19

03. Data Model 20

- ERD — Entity Relationship Diagram 20
- Сущности 20
- dbt Layers 23
- Mart-таблицы 24

04. Event Taxonomy 27

- Naming Convention 27
- Event Schema 27
- JSON Payloads 28
- Tracking Plan 30
- Процесс изменений 31

05. Metrics Dictionary 32

- Revenue 32
- Unit Economics 34
- Players 36
- Marketing 37
- Product 39

06. Data Governance 41

- Roles & Ownership 41
- Data Catalog (DataHub) 42
- Data Dictionary 42
- Access Policies (RBAC) 43
- DQ Framework 43
- Data Lifecycle 45

07. SLA 46

- SLA Matrix 46
- Incident Severity Levels 47
- Как измеряется и отслеживается 47

08. DataOps 48

- CI/CD for Data 48

Monitoring 48
On-call 49
Environments 50
09. MLOps 51
ML Lifecycle 51
Experiment Tracking (MLflow) 51
Model Registry 52
Feature Store (Feast) 52
Мониторинг моделей 53
Model Cards 53
Утилизация моделей: от score к бизнес-действию 55
10. Data Lineage 57
Пример 1: путь NGR от ставки до дашборда CEO 57
Пример 2: как считается LTV игрока 58
Пример 3: Churn Prediction Pipeline 60
11. Incident Response 62
Severity Levels 62
Response Protocol 62
Post-mortem — заполненный пример 62
12. Dashboard Mockups 65
13. A/B Testing Framework 70
HADI-цикл 70
Бэклог гипотез 70
Чеклист запуска 72
Сколько нужно данных для теста? 72
Шаблон отчёта 72
Полный кейс: упрощение формы депозита (AB-01) 73
Серая зона: неоднозначные результаты 74
Anti-patterns: как НЕ надо 75
14. Management Practices 77
Структура спринта 77
Регулярные встречи 77
1-on-1 с лидом 77
OKR Framework 78
Управление бэклогом 78
Пример: три запроса, ресурсы на один 79
Capacity Planning 79
Delegation Framework 80
База знаний 80
15. Onboarding Guide 82
День 1–3: Доступы и знакомство 82

Неделя 1: Data Tour 83
Неделя 2: Первые задачи 84
Месяц 1: Самостоятельная работа 85
Onboarding Checklist 86
16. FinOps 88
Структура затрат 88
Оптимизация затрат 89
Бюджетное планирование 91
17. Annual Roadmap 93
Timeline 93
Q1 — Stabilize 93
Q2 — Self-service 94
Q3 — ML to Prod 95
Q4 — Scale 95
Зависимости между кварталами 96
Приложение A: Glossary 98
О проекте и авторе 107
О проекте 107
Об авторе 107
Полезные материалы 107
Contributing 108
Changelog 108

01. Data Architecture

Полный стек данных Fantasy iGaming — от источников до обратной интеграции. Каждый слой раскрывается с описанием инструментов, альтернатив и trade-off.

Эта страница описывает

стека Fantasy iGaming. Текущий прогресс внедрения — в разделе

.

Кликните на любой слой, чтобы увидеть инструменты. Каждый tool card содержит: что делает, почему выбран, альтернатива и ключевой trade-off.

Первичные источники данных компании. Данные приходят из продакшн-систем, трекеров, CRM и внешних API. Напрямую к продакшн-базам аналитика не ходит — только через слой ingestion.

PostgreSQL

Основная продакшн-база: аккаунты игроков, ставки, транзакции, балансы. Содержит текущий state всех бизнес-сущностей. Никогда не используется напрямую для аналитики — нагрузка может положить прод.

MySQL, Mongo

Apache Kafka

Шина реалтайм-событий iGaming-платформы. Основные топики: bets.placed , deposits.completed , sessions.events . Во время live-матчей нагрузка на bets.placed растёт в 5-10x. Три consumer groups: бэкенд (расчёт выигрышей), аналитический pipeline (стриминг в ClickHouse), fraud-сервис (real-time scoring).

RabbitMQ, Am

GA4 + GTM

Веб-аналитика и маркетинговая атрибуция. В iGaming GA4 — не основной источник аналитики, а дополнение. Продуктовая аналитика живёт в DWH на базе собственного трекинга через Kafka. GA4 используется для маркетинговой атрибуции и анализа pre-registration поведения. GTM управляет тегами на сайте.

Amplitude, Mix

Adjust

Мобильная атрибуция: установки приложений, in-app события, маркетинговая атрибуция по каналам. Критично для понимания эффективности мобильного маркетинга.

AppsFlyer, Bra

CRM

Жизненный цикл игрока: сегментация, бонусные кампании, коммуникации. Данные о том, какие бонусы выданы, в какой сегмент попал игрок, история взаимодействий.

in-house реше

External APIs

Внешние фиды: коэффициенты (odds), результаты матчей, статусы платёжных провайдеров. Данные приходят через REST/WebSocket API от третьих сторон.

собственные

Слой загрузки данных из источников в хранилище. Два подхода: batch (Airbyte) для периодической синхронизации и CDC (Debezium) для реалтайм-захвата изменений.

Airbyte

Основной инструмент batch-загрузки. Self-hosted, 300+ готовых коннекторов к БД, API, SaaS-сервисам. Дешевле Fivetran, но требует поддержки от DE-команды: обновления, мониторинг, custom-коннекторы.

Fivetran (mana

Debezium / CDC

Change Data Capture из продакшн PostgreSQL через Kafka Connect. Захватывает только дельты (INSERT/UPDATE/DELETE), минимальная нагрузка на прод. Критичен для near-real-time аналитики: ставки, депозиты, балансы.

AWS DMS, Stri

Два уровня хранения: горячее (ClickHouse для аналитики) и холодное (GCS data lake для архивации и raw-данных).

ClickHouse

Колоночная СУБД для аналитики. Быстрые агрегации на миллиардах строк, популярна в CIS и iGaming. Self-hosted = полный контроль над данными (регуляторные требования). Основное хранилище для всех mart-таблиц.

BigQuery (se
compute/stora

GCS Data Lake

Google Cloud Storage для raw/cold данных в формате Parquet. Сырые данные хранятся здесь бессрочно. Дёшево, надёжно. Используется для re-processing, compliance (хранение 5+ лет) и ML-тренировок на исторических данных.

AWS S3, Azure

Вся трансформация данных — через dbt Core. Три слоя моделей: staging (очистка) → intermediate (бизнес-логика) → marts (готово для BI/DS). Версионирование в Git, тесты, документация из коробки.

dbt Core

SQL-first фреймворк для трансформации данных в DWH. Модели организованы в три слоя, каждая модель — SQL-файл в Git. Встроенные тесты, автодокументация, lineage graph.

Spark (тяжёл

Staging — очистка и типизация

1:1 с источником. Приведение типов, дедупликация, переименование полей. Никакой

бизнес-логики.

SQL

```
-- stg_betting__bets: очистка сырых ставок
SELECT
    bet_id,
    player_id,
    lower(product) AS product,
    game_id,
    event_id,
    CAST(bet_amount AS Decimal64(2)) AS bet_amount,
    CAST(payout_amount AS Decimal64(2)) AS payout_amount,
    lower(status) AS status,
    toDateTime(placed_at) AS placed_at,
    toDateTime(settled_at) AS settled_at
FROM raw.betting_bets
WHERE bet_id IS NOT NULL
```

Intermediate — бизнес-логика

Джойны, расчёты, обогащение. Здесь ставка обогащается данными игрока и игры.

SQL

```
-- int_bets_enriched: ставка + игрок + игра
SELECT
    b.bet_id,
    b.player_id,
    p.geo,
    p.acquisition_channel,
    b.bet_amount,
    b.payout_amount,
    b.bet_amount - b.payout_amount AS ggr,
    g.game_type,
    g.provider,
    b.placed_at
FROM stg_betting__bets b
LEFT JOIN stg_core__players p ON b.player_id = p.player_id
LEFT JOIN stg_core__games g ON b.game_id = g.game_id
```

Marts — готовые витрины

Финальные агрегаты для BI и DS. Один mart = один бизнес-вопрос.

SQL

```
-- mart_daily_kpi: NGR = GGR - bonus - provider fees - payment fees
WITH daily_ggr AS (
    SELECT
        toDate(placed_at) AS dt,
        count(DISTINCT player_id) AS active_players,
        sum(bet_amount) AS turnover,
        sum(ggr) AS ggr
    FROM int_bets_enriched
    GROUP BY dt
),
daily_costs AS (
    SELECT
        dt,
        sum(bonus_cost) AS bonus_cost,
        sum(provider_fee) AS provider_fees,
        sum(payment_fee) AS payment_fees
    FROM int_daily_costs
    GROUP BY dt
)
SELECT
    g.dt,
    g.active_players,
    g.turnover,
    g.ggr,
    g.ggr - coalesce(c.bonus_cost, 0)
           - coalesce(c.provider_fees, 0)
           - coalesce(c.payment_fees, 0) AS ngr
FROM daily_ggr g
LEFT JOIN daily_costs c ON g.dt = c.dt
ORDER BY g.dt DESC
```

Оркестрация всех data-процессов: расписание, зависимости, ретраи, алерты. Почему не cron? Потому что cron не знает про зависимости между задачами, не умеет retry, не имеет UI для мониторинга.

Apache Airflow

DAG-based оркестратор. Каждый pipeline описан как Directed Acyclic Graph: extract → load → dbt run → dbt test → alert. Web UI для мониторинга, встроенные retries, SLA alerts, интеграция со Slack.

Dagster (mode

Типичный DAG

PYTHON

```
from airflow import DAG
from datetime import datetime, timedelta

default_args = {
    'owner': 'data-engineering',
    'retries': 2,
    'retry_delay': timedelta(minutes=5),
}

dag = DAG(
    'daily_pipeline',
    default_args=default_args,
    schedule_interval='0 5 * * *',  # 05:00 UTC daily
    start_date=datetime(2024, 1, 1),
)

# Task dependencies
[extract_betting, extract_payments, extract_players] \
    >> load_to_clickhouse \
    >> dbt_run_staging \
    >> dbt_run_intermediate \
    >> dbt_run_marts \
    >> dbt_test \
    >> slack_notify
```

Расписание: ежедневно в 05:00 UTC. Данные готовы к 07:00 для утренних отчётов CEO. При падении — 2 автоматических retry с интервалом 5 минут, затем алерт в Slack.

Качество данных и управление. Три уровня защиты: dbt tests (быстрые, на каждый PR), Great Expectations (сложные валидации), DataHub (каталог и lineage). Подробнее — в разделе 06. Data Governance .

dbt tests

Встроенные тесты dbt: unique, not_null, accepted_values, relationships. Запускаются на каждый PR в CI и после каждого dbt run в production. Первая линия защиты от битых данных.

custom SQL tes

Great Expectations

Сложные валидации: распределения, аномалии, cross-table consistency. Профилирование данных, автоматическая генерация expectations на основе исторических данных.

Soda, Monte C

DataHub

Каталог данных: поиск таблиц, описания полей, владельцы, lineage, теги. Self-hosted. Интеграция с dbt (автоматический импорт моделей) и Airflow.

Atlan (manage

Визуализация и self-service аналитика. Два инструмента под разные аудитории. Подробнее о дашбордах — в разделе 12. Dashboards .

Metabase

Основной BI-инструмент. Open-source, self-hosted. Простой интерфейс для self-service: бизнес-пользователи строят отчёты без SQL. Semantic layer через «вопросы» и «коллекции».

Tableau (мощн

Looker Studio

Бесплатный BI от Google. Используется маркетинговой командой: нативная интеграция с GA4, Google Ads, Sheets. Маркетинг-дашборды живут здесь.

Google Sheets

Инфраструктура для машинного обучения: разработка моделей, эксперименты, Feature Store. Подробнее — в разделе 09. MLOps .

Python / Jupyter

Основная среда разработки моделей. Jupyter notebooks для EDA и прототипирования, Python-скрипты для production-кода. Стандартный стек: pandas, scikit-learn, LightGBM, PyTorch.

R (для специф

MLflow

Tracking экспериментов, реестр моделей, управление артефактами. Каждый эксперимент логирует параметры, метрики (AUC, MAE), версии данных. Model Registry: staging → production → archived.

Weights & Bias

Feast

Feature Store: единый реестр фичей для ML. Offline store (для тренировки) + online store (для real-time inference). Пример фичи: player_avg_bet_7d — средняя ставка игрока за 7 дней.

Tecton, Hopsw

Обратная интеграция: данные из DWH отправляются в операционные системы. Замыкает цикл: аналитика → действие.

Census

Reverse ETL: синхронизация данных из ClickHouse в CRM, рекламные платформы, email-сервисы. Ключевой use case: ML-модель считает churn score → Census отправляет его в CRM → CRM создаёт сегмент «at risk» → игрок получает персонализированный бонус.

Hightouch, cus

> *TIP: Use case: churn_score (ML) → Census → CRM segment → персонализированный бонус. Цикл: данные → модель → действие → результат → данные.*

02. Org Structure

Data-команда Fantasy iGaming — 21 человек: Director + 4 стрима по 5/8/4/3. Директор, лиды, инженеры, аналитики, DS. Кто за что отвечает, как взаимодействуют, куда расти.

Org Chart

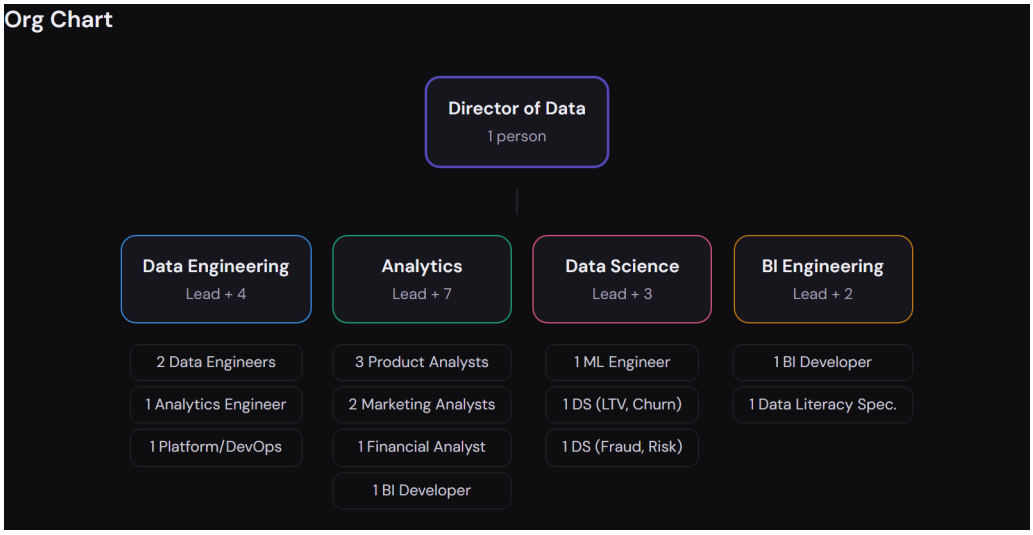

Стримы

DE Stream

Data Engineering [5 человек]

Команда

Lead Data Engineer

Архитектура DWH, код-ревью, планирование, on-call эскалации. Мост между DE и аналитикой — переводит бизнес-требования в технические задачи для инженеров.

Data Engineer × 2

Разработка и поддержка пайплайнов: Airbyte коннекторы, Kafka consumers, загрузка в ClickHouse. Мониторинг, on-call ротация.

Analytics Engineer

dbt-модели: staging → intermediate → marts. Тесты качества данных, документация моделей. Работает на стыке DE и аналитики.

Platform / DevOps Engineer

Инфраструктура data-платформы: Airflow, ClickHouse кластер, мониторинг (Grafana, alerting). CI/CD для dbt и пайплайнов.

Зона ответственности

- Ingestion: все пайплайны из источников в DWH
- DWH: схема, производительность, партиционирование ClickHouse
- Инфраструктура: Airflow, Kafka, мониторинг
- DQ на уровне пайплайнов: свежесть, полнота, схема
- On-call: ротация 1 неделя, реагирование на P1/P2 инциденты

Взаимодействие

- Backend: доступ к данным, API, схемы таблиц
- DevOps: инфраструктура, деплой, сети
- Analytics: требования к mart-таблицам, SLA по свежести

Ключевые deliverables

- Пайплайны работают 24/7
- Данные в DWH свежие к 07:00 UTC
- SLA uptime: 99.5%

Analytics Stream

Analytics [8 человек]

Команда

Lead Analyst

Приоритизация задач аналитиков, методология исследований, ревью отчётов. Представляет данные на C-level. Стратегические инсайты.

Product Analyst × 3

По направлениям: Sports, Casino, Payments. Метрики продукта, воронки, когортный анализ, A/B-тесты. Работают в связке с продуктовыми менеджерами.

Marketing Analyst × 2

Acquisition: CAC, ROAS, атрибуция по каналам. Retention/CRM: churn-анализ, бонусная эффективность, LTV по когортам.

Financial Analyst

P&L, unit economics, бюджетирование. NGR breakdown по продуктам и рынкам. Финансовая отчётность для CFO.

BI Developer

Дашборды в Metabase, семантический слой. Стандартизация отчётов, шаблоны. Мост между аналитиками и BI-инженерами.

Зона ответственности

- Регулярная отчётность: daily/weekly/monthly
- Исследования: deep dives, impact analysis

- Ad-hoc: ответы на вопросы бизнеса (SLA: 3 рабочих дня)
- Когортный анализ, воронки, сегментация

Взаимодействие

- Product: метрики фичей, A/B-тесты, user research
- Marketing: эффективность каналов, CRM-кампании
- Finance: P&L, unit economics, прогнозы
- C-level: стратегические отчёты, OKR-трекинг

Ключевые deliverables

- Дашборды актуальны и доступны
- Weekly/monthly отчёты вовремя
- Ad-hoc: ≤ 3 рабочих дня
- Исследование: ≤ 2 недели

DS Stream

Data Science [4 человека]

Команда

Lead Data Scientist

Методология, приоритизация ML-задач, ревью моделей. Координация с Product по use cases. Определяет, когда ML оправдан, а когда хватит эвристики.

ML Engineer

Деплой моделей в продакшн, MLOps инфраструктура: MLflow, Feature Store, мониторинг дрифта. Мост между DS-экспериментами и production.

Data Scientist — LTV & Churn

Предиктивные модели: LTV prediction, churn scoring, recommendation engine. Работает с product-аналитиками на когортных данных.

Data Scientist — Fraud & Risk

Real-time fraud scoring, anomaly detection, risk models. Latency SLA < 100ms. Работает с Risk/Compliance командой.

Зона ответственности

- Предиктивные модели: LTV, churn, fraud, recommendations
- A/B тестирование: методология, расчёт sample size, анализ
- Experimentation platform

Взаимодействие

- Product: use cases, приоритизация моделей
- DE: данные, Feature Store, пайплайны для моделей
- Risk/Compliance: fraud detection, ответственный гейминг

Ключевые deliverables

- Модели в production
- A/B отчёты с рекомендациями
- Fraud scoring: latency < 100ms, FPR < 5%

BI Engineering Stream

BI Engineering [3 человека]

Команда

Lead BI Engineer

Архитектура BI-слоя, стандарты визуализации, семантический слой. Координация с Lead Analyst по метрикам.

BI Developer

Сложные дашборды в Metabase, embedded analytics, кастомные визуализации. Оптимизация запросов для быстрой загрузки.

Data Literacy Specialist

Обучение бизнес-пользователей self-service аналитике. Воркшопы, документация, шаблоны. Цель — 80% ad-hoc через self-service.

Зона ответственности

- Семантический слой: единые определения метрик
- Стандартизация отчётности: шаблоны, гайдлайны
- Self-service инструменты: Metabase для бизнес-пользователей
- Data literacy программа: обучение, воркшопы

Взаимодействие

- Все бизнес-функции: конечные пользователи дашбордов
- Analytics: требования к метрикам, валидация
- DE: производительность запросов, SLA по обновлению

Ключевые deliverables

- Self-service покрытие: 80% ad-hoc через Metabase
- Data literacy: 3 воркшопа в квартал
- Стандартизированные шаблоны отчётов

RACI Matrix

Кто за что отвечает в ключевых процессах. R — Responsible (делает), A — Accountable (отвечает за результат), C — Consulted, I — Informed.

Процесс	DE	Analytics	DS	BI Eng	Director
Новый дашборд	C	R	I	A	I
Новый pipeline	R, A	C	I	I	I
Новая ML-модель	C	C	R, A	I	I
Инцидент P1	R	I	C	I	A
Новая метрика	C	R, A	C	R	I
A/B тест	I	C	R, A	I	I
Data Governance review	R	C	C	C	A

Skill Matrix

Ожидаемый уровень навыков по ролям. expert proficient basic

Роль	SQL	Python	dbt	BI	Statistics	ML	Comm.	Domain
Data Engineer	expert	prof	prof	basic	basic	basic	prof	prof
Analytics Engineer	expert	prof	expert	prof	prof	basic	prof	expert
Product Analyst	expert	prof	prof	expert	prof	basic	expert	expert
Marketing Analyst	prof	prof	basic	expert	prof	basic	expert	prof
Data Scientist	prof	expert	basic	basic	expert	expert	prof	prof
ML Engineer	prof	expert	basic	basic	prof	expert	prof	prof
BI Developer	expert	basic	prof	expert	basic	basic	prof	prof

Career Ladder

Единая карьерная лестница для всех стримов. Каждый уровень — это не только про hard skills, но и про scope of impact.

- **Junior**
  Выполняет задачи под руководством ментора Учится стандартам и процессам команды Scope: отдельные задачи (запрос, модель, тест) Срок на уровне: 1-2 года
- **Middle**
  Самостоятельно решает задачи без постоянного ревью Понимает бизнес-контекст своих задач Scope: фича / исследование / pipeline целиком Менторит джуниоров, участвует в код-ревью Срок на уровне: 2-3 года
- **Senior**
  Определяет техническое решение для сложных задач Влияет на архитектуру и процессы команды Scope: проект / направление (все спорт-аналитика, вся ingestion) Менторит middle, проводит техревью, пишет RFC Может работать кросс-функционально
- **Lead**
  Отвечает за стрим: планирование, приоритизация, people management Scope: весь стрим (DE, Analytics, DS, BI) Нанимает, проводит 1-on-1, растит людей Представляет стрим перед Director и стейкхолдерами 60% management / 40% hands-on (зависит от зрелости команды)
- **Head / Director**
  Стратегия data-функции, OKR, бюджет Scope: вся data-организация (20 человек, 4 стрима) C-level коммуникация, приоритизация на уровне компании Найм лидов, организационный дизайн 90% management / 10% hands-on (архитектурные решения)

03. Data Model

Модель данных Fantasy iGaming: 9 core entities, связи, слои dbt и готовые marts для BI и DS.

ERD — Entity Relationship Diagram

Основные сущности DWH и связи между ними. Dimensions (dim_) — справочники, Facts (fct_) — транзакционные данные.

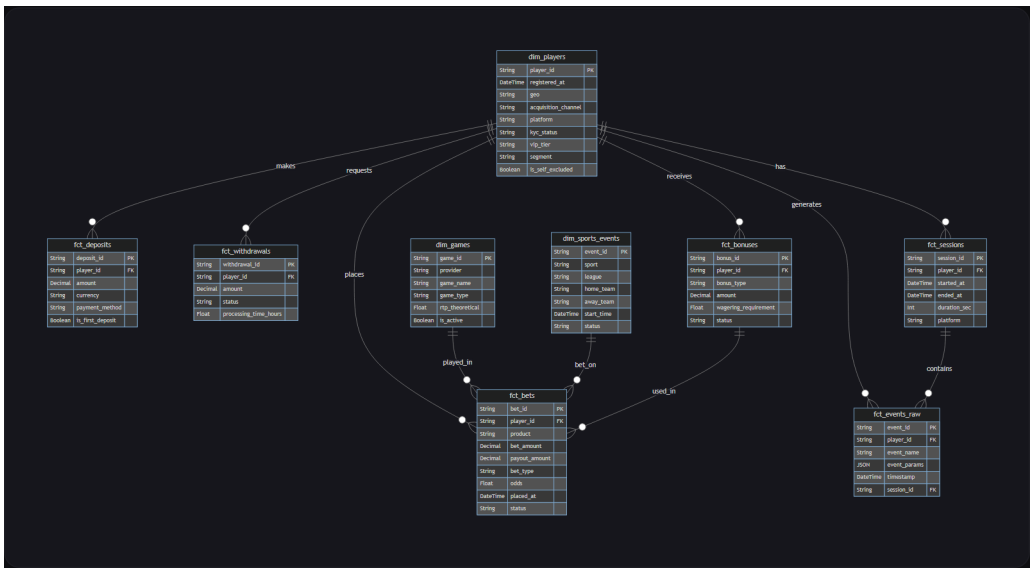

Сущности

Кликните на таблицу для просмотра полей и описаний.

dim_players

dim_players [dimension]

Справочник игроков. Одна строка = один зарегистрированный игрок. Обновляется через CDC при изменении профиля.

Field	Type	Description
player_id	String PK	Уникальный ID игрока
registered_at	DateTime	Дата и время регистрации
geo	String	Страна (ISO 3166-1 alpha-2)
acquisition_channel	String	Канал привлечения: organic, paid_search, affiliate, social
acquisition_campaign	String	UTM campaign, nullable
device	String	Устройство при регистрации
platform	String	web / ios / android
kyc_status	String	pending / verified / rejected
kyc_verified_at	DateTime	Дата верификации KYC, nullable

Field	Type	Description
vip_tier	String	bronze / silver / gold / platinum
segment	String	Бизнес-сегмент: casual, regular, vip, whale
is_self_excluded	Boolean	Самоисключение (responsible gaming)
created_at	DateTime	Дата создания записи
updated_at	DateTime	Дата последнего обновления

dim_games

dim_games [dimension]

Каталог казино-игр. Обновляется при подключении нового провайдера или игры.

Field	Type	Description
game_id	String PK	Уникальный ID игры
provider	String	Провайдер: Pragmatic Play, Evolution, NetEnt
game_name	String	Название игры
game_type	String	slot / table / live / crash
rtp_theoretical	Float	Теоретический RTP (0.90–0.99)
category	String	Категория в лобби: popular, new, jackpot
is_active	Boolean	Активна ли игра в лобби

dim_sports_events

dim_sports_events [dimension]

Справочник спортивных событий. Обновляется через odds feed. Статус: pre → live → settled.

Field	Type	Description
event_id	String PK	Уникальный ID события
sport	String	Вид спорта: football, basketball, tennis, esports
league	String	Лига / турнир
home_team	String	Домашняя команда
away_team	String	Гостевая команда
start_time	DateTime	Время начала
status	String	pre / live / settled
result	String	Результат (после settle), nullable

fct_bets

fct_bets [fact]

Все ставки: казино и спорт. Основная транзакционная таблица. ~10M строк/месяц. Партиционирование по placed_at (month).

Field	Type	Description
bet_id	String PK	Уникальный ID ставки
player_id	String FK	→ dim_players
product	String	casino / sports
game_id	String FK	→ dim_games (casino), nullable

Field	Type	Description
event_id	String FK	→ dim_sports_events (sports), nullable
bet_amount	Decimal(18,2)	Сумма ставки в USD
payout_amount	Decimal(18,2)	Выплата (0 если проигрыш)
bet_type	String	single / combo / system
odds	Float	Коэффициент (для sports)
placed_at	DateTime	Время размещения
settled_at	DateTime	Время расчёта, nullable
status	String	open / won / lost / void
is_bonus_bet	Boolean	Ставка за счёт бонуса
bonus_id	String FK	→ fct_bonuses, nullable

fct_deposits

fct_deposits [fact]

Все депозиты. Критичная таблица для revenue-метрик. is_first_deposit — ключ для FTD-аналитики.

Field	Type	Description
deposit_id	String PK	Уникальный ID депозита
player_id	String FK	→ dim_players
amount	Decimal(18,2)	Сумма в оригинальной валюте
currency	String	USD, EUR, BRL
payment_method	String	card, crypto, e-wallet, bank_transfer
status	String	pending / completed / failed
is_first_deposit	Boolean	FTD — first time deposit
fee_amount	Decimal(18,2)	Комиссия платёжной системы
created_at	DateTime	Время создания

fct_withdrawals

fct_withdrawals [fact]

Выводы средств. Время обработки — ключевая метрика для продукта и compliance.

Field	Type	Description
withdrawal_id	String PK	Уникальный ID вывода
player_id	String FK	→ dim_players
amount	Decimal(18,2)	Сумма вывода
currency	String	Валюта
payment_method	String	Метод вывода
status	String	pending / approved / rejected / completed
processing_time_hours	Float	Время обработки в часах
created_at	DateTime	Время запроса

fct_sessions

fct_sessions [fact]

Сессии пользователей. Engagement-метрики и поведенческий анализ.

Field	Type	Description
session_id	String PK	Уникальный ID сессии
player_id	String FK	→ dim_players
started_at	DateTime	Начало сессии
ended_at	DateTime	Конец сессии
duration_sec	Int	Длительность в секундах
platform	String	web / ios / android
device_type	String	mobile / tablet / desktop
pages_viewed	Int	Количество просмотренных страниц
geo_ip	String	Гео по IP

fct_bonuses

fct_bonuses [fact]

Бонусы. Ключевая таблица для расчёта bonus cost (компонент NGR). Вейджер — сколько нужно проставить для вывода.

Field	Type	Description
bonus_id	String PK	Уникальный ID бонуса
player_id	String FK	→ dim_players
bonus_type	String	welcome / reload / cashback / freebet / freespin
amount	Decimal(18,2)	Сумма бонуса
wagering_requirement	Float	Множитель вейджера (напр. 30x)
wagered_amount	Decimal(18,2)	Сколько проставлено
status	String	active / completed / expired / cancelled
issued_at	DateTime	Дата выдачи
expires_at	DateTime	Дата истечения

fct_events_raw

fct_events_raw [fact]

Сырые события трекинга. Semi-structured: event_params — JSON. Source для Event Taxonomy .

Field	Type	Description
event_id	String PK	UUID события
player_id	String FK	→ dim_players
event_name	String	Имя события (см. Event Taxonomy)
event_params	JSON	Параметры, schema-on-read
timestamp	DateTime	Время события (ISO 8601)
session_id	String FK	→ fct_sessions
platform	String	web / ios / android

dbt Layers

Три слоя трансформации. Подробнее о стеке — в 01. Data Architecture .

Staging (stg_)

1:1 с источником. Очистка, типизация, дедупликация. Без бизнес-логики.

SQL

```
-- stg_betting__bets
SELECT
    bet_id,
    player_id,
    lower(product) AS product,
    game_id,
    event_id,
    CAST(bet_amount AS Decimal64(2)) AS bet_amount,
    CAST(payout_amount AS Decimal64(2)) AS payout_amount,
    lower(status) AS status,
    toDateTime(placed_at) AS placed_at,
    toDateTime(settled_at) AS settled_at
FROM raw.betting_bets
WHERE bet_id IS NOT NULL
```

Intermediate (int_)

Джойны, расчёты, обогащение данных.

SQL

```
-- int_bets_enriched
SELECT
    b.bet_id,
    b.player_id,
    p.geo,
    p.vip_tier,
    p.acquisition_channel,
    b.product,
    b.bet_amount,
    b.payout_amount,
    b.bet_amount - b.payout_amount AS ggr,
    b.is_bonus_bet,
    g.game_type,
    g.provider,
    b.placed_at
FROM stg_betting__bets b
LEFT JOIN stg_core__players p ON b.player_id = p.player_id
LEFT JOIN stg_core__games g ON b.game_id = g.game_id
```

Marts (mart_)

Финальные витрины для BI и DS. Каждый mart отвечает на конкретный бизнес-вопрос.

Mart-таблицы

mart_daily_kpi [daily refresh]

Ежедневные бизнес-метрики. Основной дашборд CEO. Обновляется к 07:00 UTC.

Sources: int_bets_enriched, int_daily_costs

- dt — дата
- active_players — уникальные игроки за день
- turnover — сумма ставок (handle)
- ggr — Gross Gaming Revenue
- ngr — Net Gaming Revenue (GGR - bonus - fees)
- deposits , withdrawals — суммы
- ftd_count — новые депозиторы

mart_player_lifetime [daily refresh]

Lifetime-метрики по каждому игроку. Основа для LTV-моделей и сегментации.

Sources: int_bets_enriched, int_deposits, int_sessions

- player_id — ID игрока
- lifetime_turnover — все ставки за всё время
- lifetime_ggr — cumulative GGR
- lifetime_deposits — сумма депозитов
- total_bets — количество ставок
- days_active — дней с активностью
- last_activity_at — последняя активность
- churn_risk — score из ML-модели

mart_cohort_analysis [weekly refresh]

Когортный анализ по дате регистрации. Retention, cumulative NGR, LTV по когортам.

Sources: int_bets_enriched, stg_core__players

- cohort_month — месяц регистрации
- period_number — месяц жизни когорты (0, 1, 2...)
- cohort_size — размер когорты
- retained_players — активные в период
- retention_rate — % retained
- cumulative_ngr — накопленный NGR

mart_marketing_performance [daily refresh]

Эффективность маркетинга: CAC, LTV:CAC, ROAS по каналам и кампаниям.

Sources: int_deposits_enriched, stg_core__players, stg_marketing__spend

- channel — канал привлечения
- campaign — кампания
- spend — маркетинговые расходы
- registrations — регистрации
- ftd_count — первые депозиты
- cac — cost per acquisition
- ltv_cac_ratio — LTV / CAC
- roas — return on ad spend

mart_game_performance [daily refresh]

Эффективность казино-игр: GGR по провайдерам, фактический vs теоретический RTP, топ-игры. Основной mart для продуктовой команды казино.

Sources: int_bets_enriched, stg_core__games

- game_id — ID игры
- provider — провайдер (Pragmatic Play, Evolution и др.)
- game_type — slot / table / live / crash
- total_bets — количество ставок
- turnover — сумма ставок
- ggr — GGR по игре
- theoretical_rtp — теоретический RTP
- actual_rtp — фактический RTP (payout / turnover)
- unique_players — уникальные игроки

04. Event Taxonomy

Единая система именования событий, стандартная схема, tracking plan и процесс добавления новых событий.

Naming Convention

Все события следуют формату: {domain}_{object}_{action} . Это обеспечивает единообразие, сортировку и фильтрацию.

Domains

Domain	Description	Примеры
player	Действия игрока	player_bet_placed, player_deposit_completed
session	Сессия и навигация	session_page_viewed, session_started
marketing	Маркетинг и кампании	marketing_campaign_clicked, marketing_banner_viewed
system	Системные события	system_error_occurred, system_maintenance_started

Objects

TEXT

```
bet, deposit, withdrawal, bonus, session, page,
registration, kyc, game, promo, notification
```

Actions

TEXT

```
placed, completed, started, viewed, settled,
issued, expired, cancelled, failed, clicked
```

> *TIP: Правило: если не можете описать событие в формате domain_object_action — скорее всего, это не одно событие, а два.*

Event Schema

Стандартная структура каждого события. Все поля обязательны кроме event-specific.

Required fields [required]

Field	Type	Description
event_name	String	Имя события (naming convention)
event_id	UUID	Уникальный ID события
player_id	String	ID игрока (null для анонимных)

Field	Type	Description
timestamp	ISO 8601	Время события с timezone
session_id	String	ID текущей сессии
platform	String	web / ios / android

Context fields (auto-collected) [auto]

Field	Type	Description
geo_ip	String	Страна по IP
device_type	String	mobile / tablet / desktop
app_version	String	Версия приложения (для mobile)
page_url	String	URL страницы (для web)
user_agent	String	User-Agent браузера

Event-specific fields [varies]

Зависят от типа события. Примеры:

- player_bet_placed : bet_amount, product, game_id, odds, bet_type
- player_deposit_completed : amount, currency, payment_method, is_first_deposit
- session_page_viewed : page_name, referrer, load_time_ms

JSON Payloads

player_bet_placed

JSON

```
{
  "event_name": "player_bet_placed",
  "event_id": "a1b2c3d4-e5f6-7890-abcd-ef1234567890",
  "player_id": "usr_28491",
  "timestamp": "2026-03-15T14:23:01.456Z",
  "session_id": "ses_9f8e7d6c",
  "platform": "ios",
  "context": {
    "geo_ip": "BR",
    "device_type": "mobile",
    "app_version": "4.2.1"
  },
  "properties": {
    "bet_amount": 25.00,
    "product": "sports",
    "match_id": "evt_champions_league_final",
    "bet_type": "single",
    "odds": 2.15,
    "market": "match_winner",
    "is_live": true,
    "is_bonus_bet": false
  }
}
```

player_deposit_completed

JSON

```
{
  "event_name": "player_deposit_completed",
  "event_id": "b2c3d4e5-f6a7-8901-bcde-f12345678901",
  "player_id": "usr_28491",
  "timestamp": "2026-03-15T14:20:33.789Z",
  "session_id": "ses_9f8e7d6c",
  "platform": "ios",
  "properties": {
    "amount": 100.00,
    "currency": "USD",
    "payment_method": "card",
    "is_first_deposit": false,
    "fee_amount": 2.50,
    "processing_time_ms": 3200
  }
}
```

session_page_viewed

JSON

```
{
  "event_name": "session_page_viewed",
  "event_id": "c3d4e5f6-a7b8-9012-cdef-123456789012",
  "player_id": "usr_28491",
  "timestamp": "2026-03-15T14:19:45.123Z",
  "session_id": "ses_9f8e7d6c",
  "platform": "ios",
  "properties": {
    "page_name": "sportsbook/football",
    "referrer": "sportsbook/home",
    "load_time_ms": 420
  }
}
```

player_registration_completed

JSON

```
{
  "event_name": "player_registration_completed",
  "event_id": "d4e5f6a7-b8c9-0123-defa-234567890123",
  "player_id": "usr_52837",
  "timestamp": "2026-03-15T10:05:12.001Z",
  "session_id": "ses_1a2b3c4d",
  "platform": "web",
  "properties": {
    "method": "email",
    "acquisition_channel": "paid_search",
    "utm_source": "google",
    "utm_campaign": "brand_latam_q1",
    "geo": "BR",
    "promo_code": "WELCOME100"
  }
}
```

Tracking Plan

Ключевые события, отслеживаемые платформой. Полный каталог — в Data Catalog (DataHub).

Event	Trigger	Key Params	Source	Owner	Status
player_registration_completed	Игрок завершил регистрацию	method, channel, geo	backend	Product	live
player_kyc_completed	KYC верификация пройдена	kyc_status, document_type	backend	Compliance	live
player_deposit_completed	Депозит зачислен	amount, currency, method, is_ftd	backend	Payments	live
player_withdrawal_requested	Игрок запросил вывод	amount, currency, method	backend	Payments	live
player_bet_placed	Ставка размещена	amount, product, odds, bet_type	backend	Product	live
player_bet_settled	Ставка рассчитана	payout, result, settled_at	backend	Product	live
player_bonus_issued	Бонус выдан игроку	bonus_type, amount, wager_req	backend	CRM	live
session_started	Игрок открыл приложение/сайт	platform, device_type	frontend	Product	live
session_page_viewed	Переход на страницу	page_name, referrer, load_time	frontend	Product	live
player_game_launched	Игрок запустил казино-игру	game_id, provider, game_type	frontend	Product	live
marketing_campaign_clicked	Клик по маркетинговому баннеру	campaign_id, placement, creative	frontend	Marketing	live
player_self_excluded	Игрок активировал самоисключение	exclusion_period, reason	backend	Compliance	live
system_error_occurred	Ошибка в системе	error_code, service, stack_trace	server	DE	live

Event	Trigger	Key Params	Source	Owner	Status
player_notification_sent	Push/email/SMS отправлен	channel, template_id, campaign	server	CRM	planned
player_promo_redeemed	Промокод использован	promo_code, discount_type	backend	Marketing	planned

Процесс изменений

Как добавить новое событие или изменить существующее. Каждое изменение проходит ревью.

- **1. Request**
  Продакт/аналитик создаёт тикет в Jira с описанием: зачем нужно событие, когда должно срабатывать, какие параметры. Шаблон: event_name, trigger, properties, source.
- **2. Review**
  Ревью двумя сторонами: Analytics (бизнес-смысл, naming convention, дубликаты) + DE (техническая реализуемость, нагрузка, формат данных). Согласование за 2 рабочих дня.
- **3. Spec**
  Финальная спецификация: JSON schema, trigger condition, validation rules. Добавляется в Tracking Plan (DataHub). Версионирование: v1, v2, etc.
- **4. Implementation**
  Backend/frontend разработчик реализует отправку события. PR с тегом [tracking] для фильтрации.
- **5. QA**
  Проверка на staging: событие приходит, формат верный, все обязательные поля заполнены. Аналитик валидирует в Kafka UI / ClickHouse.
- **6. Deploy**
  Деплой в production. Мониторинг первые 24 часа: объём событий, NULL rate, ошибки парсинга. Статус в Tracking Plan: planned → live.

> *WARNING: Deprecation: событие нельзя просто удалить. Сначала статус → deprecated , затем 30 дней grace period (для миграции потребителей), потом удаление из кода.*

05. Metrics Dictionary

18 ключевых метрик iGaming-бизнеса. Каждая метрика: определение, формула, SQL, бенчмарки, alert thresholds и типичные ошибки интерпретации.

Метрики сгруппированы по категориям: Revenue, Unit Economics, Players, Marketing, Product. SQL-примеры используют mart-таблицы из

.

Здесь представлены 18 ключевых метрик (L1). Полный каталог (50+ метрик с бенчмарками и alert thresholds) доступен в репозитории проекта.

Revenue

Turnover

Turnover / Handle [revenue]

Общая сумма всех ставок за период. Ключевой показатель объёма — не путать с выручкой.

```
Turnover = SUM(bet_amount)
```

SQL

```
SELECT
    toDate(placed_at) AS dt,
    countIf(product = 'casino') AS casino_bets,
    countIf(product = 'sports') AS sports_bets,
    sum(bet_amount) AS turnover
FROM fct_bets
WHERE placed_at >= today() - 30
GROUP BY dt
ORDER BY dt DESC
```

Benchmarks: EU: $50-200M/мес, LatAm: $20-80M/мес, SEA: $30-120M/мес

Alerts: red < 70% от avg за 4 недели yellow < 85%

Подводные камни: Turnover ≠ revenue. Высокий turnover с низкой маржой — плохой знак. Бонусные ставки раздувают turnover без реальных денег. Сравнивайте только рассчитанные (won, lost) ставки.

GGR

GGR (Gross Gaming Revenue) [revenue]

Валовой игорный доход — разница между ставками и выплатами. То, что компания «выигрывает» у игроков до вычета расходов.

```
GGR = SUM(bet_amount) - SUM(payout_amount)
```

SQL

```
SELECT
    toDate(placed_at) AS dt,
    sum(bet_amount) - sum(payout_amount) AS ggr
FROM int_bets_enriched
WHERE status IN ('won', 'lost')
GROUP BY dt
```

Benchmarks: EU: $3-15M/мес, LatAm: $1-5M/мес, SEA: $2-8M/мес

Alerts: red < 60% от avg yellow < 80%

Подводные камни: GGR может быть отрицательным в отдельные дни (джекпот, крупный выигрыш). Не включает бонусные расходы — для реальной выручки смотрите NGR. Сезонность: крупные турниры (ЧМ, Евро) резко меняют GGR.

GGR Margin

GGR Margin [revenue]

Доля GGR от turnover. Показывает «hold» — сколько процентов ставок остаётся у компании.

```
GGR Margin = GGR / Turnover × 100%
```

SQL

```
SELECT
    product,
    sum(ggr) / nullIf(sum(turnover), 0) * 100 AS ggr_margin_pct
FROM mart_daily_kpi
WHERE dt >= today() - 30
GROUP BY product
```

Benchmarks: Casino: 3-5%, Sports pre-match: 7-10%, Sports live: 5-8%

Alerts: red Casino < 2% yellow Casino < 3%

Подводные камни: Casino margin стабильнее (определяется RTP), sports margin волатильнее (зависит от результатов). Низкая маржа при высоком обороте может быть ОК для привлечения. Бонусы искусственно снижают маржу.

NGR

NGR (Net Gaming Revenue) [revenue]

Чистый игорный доход — то, что бизнес реально зарабатывает после всех операционных расходов на уровне транзакции.

```
NGR = GGR - Bonus Cost - Provider Fees - Payment Fees
```

SQL

```
SELECT
    dt,
    ggr - coalesce(bonus_cost, 0)
        - coalesce(provider_fees, 0)
        - coalesce(payment_fees, 0) AS ngr
FROM mart_daily_kpi
ORDER BY dt DESC
```

Benchmarks: ~$5M/мес для компании масштаба Fantasy iGaming

Alerts: red < 50% от target yellow < 80%

Подводные камни: NGR — основная метрика для CEO, но не включает marketing spend и payroll. Bonus cost может составлять 30-50% GGR в агрессивной стратегии. Не путать с Net Revenue (который включает ещё и налоги).

NGR Margin

NGR Margin [revenue]

Доля NGR от GGR. Показывает, сколько из валового дохода остаётся после операционных расходов.

```
NGR Margin = NGR / GGR × 100%
```

SQL

```
SELECT
    toMonth(dt) AS month,
    sum(ngr) / nullIf(sum(ggr), 0) * 100 AS ngr_margin_pct
FROM mart_daily_kpi
GROUP BY month
```

Benchmarks: Healthy: 55-75%, Aggressive promo: 40-55%

Alerts: red < 40% yellow < 55%

Подводные камни: Низкий NGR Margin — не всегда плохо (может быть инвестицией в рост через бонусы). Сравнивайте с LTV:CAC. Провайдерские комиссии фиксированы — при росте GGR margin растёт.

Unit Economics

LTV

LTV (Lifetime Value) [unit economics]

Прогнозируемый чистый доход с одного игрока за всё время. Основа для принятия решений о привлечении.

```
LTV = Avg NGR per player per month × Avg lifetime (months)
```

SQL

```
SELECT
    acquisition_channel,
    avg(lifetime_ngr) AS avg_ltv
FROM mart_player_lifetime
WHERE days_active > 30
GROUP BY acquisition_channel
```

Benchmarks: EU: $150-500, LatAm: $80-250, SEA: $50-200

Alerts: red LTV:CAC < 1.5 yellow LTV:CAC < 3.0

Подводные камни: LTV — прогноз, не факт. Чем моложе когорта, тем менее надёжен LTV. Whale-игроки резко завышают средний LTV — смотрите медиану. LTV должен считаться на базе NGR, не GGR.

LTV:CAC

LTV:CAC Ratio [unit economics]

Отношение lifetime value к стоимости привлечения. Показывает рентабельность маркетинга.

```
LTV:CAC = LTV / CAC
```

SQL

```
SELECT
    channel,
    avg(ltv_cac_ratio) AS avg_ratio
FROM mart_marketing_performance
WHERE dt >= today() - 90
GROUP BY channel
```

Benchmarks: Target: > 3.0, Acceptable: 2.0-3.0, Danger: < 1.5

Подводные камни: LTV:CAC > 5 может означать недостаточные инвестиции в рост. Для новых рынков допустим 1.5-2.0 на старте. Сравнивать по каналам — organic всегда искажает среднее.

CAC

CAC (Customer Acquisition Cost) [unit economics]

Стоимость привлечения одного депозитора. Считается по FTD (first time depositors), не по регистрациям.

```
CAC = Marketing Spend / FTD Count
```

SQL

```
SELECT
    channel,
    sum(spend) / nullIf(sum(ftd_count), 0) AS cac
FROM mart_marketing_performance
WHERE dt >= today() - 30
GROUP BY channel
```

Benchmarks: EU: $50-150, LatAm: $20-60, SEA: $15-50

Alerts: red > LTV/1.5 yellow > LTV/3

Подводные камни: CAC по регистрациям ≠ CAC по FTD. Конверсия Reg→FTD может быть 20-40%, поэтому CPA и CAC — разные метрики. Organic трафик снижает blended CAC, маскируя проблемы в paid.

Payback Period

Payback Period [unit economics]

Время, за которое NGR с игрока окупает его CAC. Чем короче — тем быстрее возврат инвестиций.

```
Payback = CAC / Avg Monthly NGR per player
```

SQL

```
SELECT
    channel,
    cac,
    roas,
    CASE WHEN roas > 0 THEN round(1 / (roas / 12), 1) ELSE NULL END AS payback_months
FROM mart_marketing_performance
WHERE dt = (SELECT max(dt) FROM mart_marketing_performance)
ORDER BY payback_months
```

Benchmarks: Target: < 6 мес, Acceptable: 6-12 мес, Danger: > 12 мес

Подводные камни: Зависит от retention — если churn высокий, payback может никогда не наступить. Для VIP-игроков payback часто 1-2 месяца, для casual — 8-12. Не путать с ROI.

Players

Active Players

Active Players (DAU / WAU / MAU) [players]

Уникальные игроки, сделавшие хотя бы одну ставку за период. DAU — день, WAU — неделя, MAU — месяц.

```
MAU = COUNT(DISTINCT player_id) WHERE placed_bet IN last 30 days
```

SQL

```
SELECT
    count(DISTINCT player_id) AS mau
FROM int_bets_enriched
WHERE placed_at >= today() - 30
```

Benchmarks: Fantasy iGaming: ~500K MAU, DAU/MAU (stickiness): 15-25%

Alerts: red DAU < 70% от avg yellow < 85%

Подводные камни: Определение «active» критично: ставка vs логин vs депозит. Мы считаем по ставкам. WAU/DAU перекрываются — не складывать. Сезонность: крупные турниры дают +30-50% DAU.

FTD Count

FTD Count [players]

Количество первых депозитов за период. Основной KPI привлечения — именно FTD, не регистрации.

```
FTD Count = COUNT(*) WHERE is_first_deposit = true
```

SQL

```
SELECT
    toDate(created_at) AS dt,
    count(*) AS ftd_count
FROM fct_deposits
WHERE is_first_deposit = 1
  AND status = 'completed'
GROUP BY dt
```

Benchmarks: 5K-20K FTD/мес для компании масштаба Fantasy iGaming

Alerts: red < 60% от target yellow < 80%

Подводные камни: FTD ≠ регистрация. Конверсия Reg→FTD обычно 25-40%. Фрод может раздувать FTD (мульти-аккаунты). Не все FTD одинаковы — смотрите средний размер первого депозита.

Retention

Retention D1 / D7 / D30 [players]

Доля игроков, вернувшихся на день 1/7/30 после первой ставки. Показывает «липкость» продукта.

```
Retention Dn = Players active on Day n / Cohort size × 100%
```

SQL

```
SELECT
    cohort_month,
    period_number,
    retention_rate
FROM mart_cohort_analysis
WHERE period_number IN (1, 7, 30)
ORDER BY cohort_month, period_number
```

Benchmarks: D1: 30-45%, D7: 15-25%, D30: 8-15%

Alerts: red D7 < 10% yellow D7 < 15%

Подводные камни: Welcome bonus искусственно завышает D1-D7. Настоящий retention видно после D30+. Retention по ставкам ≠ retention по логинам. Sports retention привязан к расписанию матчей.

Churn Rate

Churn Rate [players]

Доля игроков, прекративших активность. Определение: нет ставок 30+ дней. Обратная сторона retention.

```
Churn Rate = Churned players / Active players at period start × 100%
```

SQL

```
SELECT
    countIf(last_activity_at < today() - 30)
    / count(*) * 100 AS churn_rate_pct
FROM mart_player_lifetime
WHERE lifetime_turnover > 0
```

Benchmarks: Monthly churn: 5-10% (EU), 8-15% (LatAm)

Alerts: red > 15% monthly yellow > 10%

Подводные камни: 30 дней — условный порог, для sports можно использовать 45 (межсезонье). Неактивный ≠ ушедший — часть игроков возвращается. Churn VIP-игроков критичнее по влиянию на revenue.

Marketing

CPA/CPD

CPA / CPD [marketing]

CPA — стоимость привлечения регистрации. CPD — стоимость привлечения депозитора. В iGaming CPD (= CAC) важнее CPA.

```
CPA = Spend / Registrations | CPD = Spend / FTD
```

SQL

```
SELECT
    channel,
    sum(spend) / nullIf(sum(registrations), 0) AS cpa,
    sum(spend) / nullIf(sum(ftd_count), 0) AS cpd
FROM mart_marketing_performance
WHERE dt >= today() - 30
GROUP BY channel
```

Benchmarks: CPA: $10-40, CPD: $30-100 (EU)

Подводные камни: CPA без конверсии в FTD бессмыслен. Affiliate CPA кажется дешевле, но качество трафика ниже. Фрод раздувает количество регистраций.

ROAS

ROAS [marketing]

Return on Ad Spend — сколько NGR приносит каждый доллар маркетинговых расходов.

```
ROAS = NGR from acquired players / Marketing Spend
```

SQL

```
SELECT
    channel,
    roas
FROM mart_marketing_performance
WHERE dt >= today() - 30
ORDER BY roas DESC
```

Benchmarks: Target: > 3.0x, Break-even: 1.0x

Подводные камни: ROAS зависит от окна атрибуции (7 дней vs lifetime). Краткосрочный ROAS может быть низким, но lifetime ROAS — высоким. Органика каннибализирует paid — смотрите инкрементальность.

Conversion Funnel

Conversion Funnel (Visit → Reg → FTD) [marketing]

Воронка конверсии: от визита до первого депозита. Каждый этап — точка потери.

```
Visit→Reg: 5-15% | Reg→FTD: 25-40% | Visit→FTD: 2-5%
```

SQL

```
SELECT
    channel,
    registrations / nullIf(visits, 0) * 100 AS visit_to_reg_pct,
    ftd_count / nullIf(registrations, 0) * 100 AS reg_to_ftd_pct
FROM mart_marketing_performance
WHERE dt >= today() - 30
```

Benchmarks: Visit→Reg: 8-12%, Reg→FTD: 30-40%

Подводные камни: Конверсия сильно зависит от гео и канала. Affiliate трафик может иметь высокий Reg% но низкий FTD%. Welcome bonus поднимает Reg→FTD, но может привлекать бонус-хантеров.

Product

Revenue Concentration

Revenue Concentration [product]

Доля GGR от top-N% игроков. Высокая концентрация = зависимость от whale-игроков = risk.

```
Top 1% GGR Share = GGR from top 1% players / Total GGR × 100%
```

SQL

```
SELECT
    sum(IF(rn <= total * 0.01, lifetime_ggr, 0))
    / sum(lifetime_ggr) * 100 AS top1_pct_share
FROM (
    SELECT lifetime_ggr,
        row_number() OVER(ORDER BY lifetime_ggr DESC) AS rn,
        count(*) OVER() AS total
    FROM mart_player_lifetime
    WHERE lifetime_ggr > 0
)
```

Benchmarks: Top 1% = 20-40% GGR, Top 10% = 60-80% GGR

Alerts: red Top 1% > 50% yellow Top 1% > 35%

Подводные камни: Высокая концентрация — нормально для iGaming, но > 50% от одного сегмента — red flag. Уход одного whale-игрока = заметное падение revenue. Ответственный гейминг: whale может быть проблемным игроком.

Bonus Cost Ratio

Bonus Cost Ratio [product]

Доля GGR, потраченная на бонусы. Показывает стоимость маркетингового инструмента №1 в iGaming.

```
Bonus Cost Ratio = Total Bonus Cost / GGR × 100%
```

SQL

```
SELECT
    toMonth(dt) AS month,
    sum(bonus_cost) / nullIf(sum(ggr), 0) * 100
      AS bonus_cost_ratio_pct
FROM mart_daily_kpi
GROUP BY month
```

Benchmarks: Healthy: 10-20%, Aggressive: 25-40%, Mature market: 8-15%

Alerts: red > 40% yellow > 25%

Подводные камни: Высокий ratio — не всегда плохо (новый рынок, агрессивный рост). Но если ratio растёт, а retention не улучшается — бонусы неэффективны. Бонус-абьюзеры раздувают ratio без отдачи.

06. Data Governance

Кто владеет данными, как они каталогизированы, кто имеет доступ, как проверяется качество и сколько данные живут.

Roles & Ownership

Data Owners

Бизнес-руководители, принимающие решения о данных своего домена: доступ, качество, retention, определения метрик.

Domain	Owner	Owns	Decides
Betting	Head of Product	fct_bets, dim_games, dim_sports_events	Определения bet-метрик, доступ к raw betting data
Finance	CFO	mart_daily_kpi (revenue), fct_deposits, fct_withdrawals	Формулы NGR/GGR, финансовая отчётность, аудит
Marketing	CMO	mart_marketing_performance, attribution data	Модели атрибуции, доступ к маркетинговым расходам
Player PII	Head of Compliance	dim_players (PII fields), KYC data	Доступ к PII, retention PII, GDPR requests

Data Stewards

Аналитик или DE, назначенный на домен. Отвечает за операционное качество: мониторит свежесть, чинит аномалии, поддерживает документацию.

Пример: Steward для mart_daily_kpi — Financial Analyst.

- Проверяет данные каждое утро к 07:30 UTC
- Валидирует NGR: сравнивает с платёжным отчётом
- Эскалирует расхождения > 0.5% в #data-alerts
- Обновляет документацию при изменении формул

Governance Council

Состав: Director of Data (chair), все Data Owners, Lead Analyst, Lead DE.

Cadence: Ежеквартально, 1.5 часа.

Типичная повестка:

- Ревью DQ score по доменам
- Новые определения метрик (спорные случаи)
- Запросы на доступ к PII
- Изменения retention policy

Пример решения: Q1 2026 — утверждение новой формулы Churn Rate (с 30 на 45 дней для sports-only игроков, на основе анализа сезонности).

Data Catalog (DataHub)

Централизованный каталог: поиск таблиц, описания полей, владельцы, lineage. Self-hosted, интеграция с dbt и Airflow.

Пример карточки таблицы

Table	mart_daily_kpi
Description	Ежедневные KPI: NGR, GGR, active players, deposits. Основной mart для CEO dashboard.
Owner	CFO (Data Owner), Financial Analyst (Steward)
Freshness	Daily, updated by 07:00 UTC
Lineage	int_bets_enriched → int_daily_costs → mart_daily_kpi → Metabase CEO Pulse
Tags	revenue critical certified
Popularity	47 queries/day (top-5 most used)
DQ Score	98.5% (last 30 days)

Data Dictionary

Стандартизированные определения ключевых терминов. Единый источник правды — если два человека спорят о значении метрики, побеждает Data Dictionary.

Term	Definition	Notes
Active Player	Игрок, сделавший хотя бы 1 ставку за последние 30 дней	Не логин, не депозит — именно ставка
FTD	First Time Depositor — игрок, совершивший первый депозит	Считается по completed deposits, не pending
GGR	SUM(bet_amount) - SUM(payout_amount) по settled bets	Только settled, не open/void
NGR	GGR - bonus_cost - provider_fees - payment_fees	Не включает marketing spend и payroll
Churn	Игрок без ставок 30+ дней (45 для sports-only)	Утверждено Governance Council Q1 2026
Whale	Игрок в top-1% по lifetime GGR	Требует responsible gaming мониторинга
Bonus Cost	Сумма бонусных средств, использованных для ставок	Не выданных, а фактически использованных

Процесс изменения определений

- **1. Proposal**
  Аналитик или Product создаёт RFC в Confluence: текущее определение, предлагаемое, обоснование, impact analysis.
- **2. Review**
  Data Owner домена + Lead Analyst ревьюят. Если cross-domain — выносится на Governance Council.
- **3. Approve & Update**
  Обновление в Data Dictionary, DataHub, dbt docs. Уведомление в #data-announcements. Grace period 2 недели для даунстрим-потребителей.

Access Policies (RBAC)

Role-Based Access Control. Принцип least privilege: каждая роль получает только необходимый доступ.

Role	Betting	Finance	Player PII	Marketing
Analyst	read	read	masked	read
Data Scientist	read	no	masked	read
BI Developer	read	read	no	read
Lead	read	read	masked	read
Director	full	full	full	full

> *INFO: Masked = PII-поля (email, phone, name) заменяются хэшем. player_id доступен для джойнов, но идентификация невозможна. Доступ к raw PII — только через запрос к Head of Compliance с обоснованием.*

Row-Level Security — пример

SQL

```sql
-- Marketing Analyst видит только marketing-related данные
CREATE ROW POLICY marketing_only ON mart_marketing_performance
FOR SELECT
USING currentUser() IN ('marketing_analyst_1', 'marketing_analyst_2')
TO marketing_team;
```

DQ Framework

5 измерений качества данных. Каждое измерение — набор автоматизированных тестов (dbt tests + Great Expectations). Подробнее о стеке — 01. Data Architecture .

Completeness [dimension]

Полнота данных — отсутствие NULL в обязательных полях.

YAML

```yaml
# dbt test: payment_method completeness
- name: fct_deposits
  columns:
    - name: payment_method
      tests:
        - not_null:
            config:
              severity: warn
              warn_if: "> 1%"
              error_if: "> 5%"
```

Target: % NULL в payment_method < 1%

Accuracy [dimension]

Точность — данные соответствуют реальности.

SQL

```
-- Great Expectations: actual RTP vs theoretical
SELECT
    game_id,
    abs(actual_rtp - theoretical_rtp) AS rtp_diff
FROM mart_game_performance
WHERE total_bets > 10000
  AND abs(actual_rtp - theoretical_rtp) > 0.02
```

Target: actual RTP vs theoretical ±2pp для игр с 10K+ ставок

Timeliness [dimension]

Своевременность — данные обновляются по расписанию.

SQL

```
-- Мониторинг: системная таблица (не часть аналитической модели)
-- Airflow sensor: mart updated by 7:00 UTC
SELECT
    table_name,
    last_updated_at,
    dateDiff('minute', last_updated_at, now()) AS staleness_min
FROM meta.table_freshness
WHERE staleness_min > 120 -- stale > 2 hours
```

Target: critical marts обновлены к 07:00 UTC, staleness < 2 часов

Consistency [dimension]

Согласованность — одни и те же данные совпадают между таблицами.

SQL

```
-- Cross-table consistency check
SELECT
    abs(
        (SELECT sum(bet_amount) FROM fct_bets WHERE toDate(placed_at) = today() - 1)
        - (SELECT turnover FROM mart_daily_kpi WHERE dt = today() - 1)
    ) / nullIf(
        (SELECT turnover FROM mart_daily_kpi WHERE dt = today() - 1), 0
    ) * 100 AS diff_pct
```

Target: SUM(fct_bets.bet_amount) = mart_daily_kpi.turnover ±0.01%

Uniqueness [dimension]

Уникальность — нет дубликатов по primary key.

YAML

```
# dbt test: no duplicates on bet_id
- name: fct_bets
  columns:
    - name: bet_id
      tests:
        - unique
        - not_null
```

Target: 0 дубликатов на bet_id, deposit_id, player_id

Data Lifecycle

Retention policy: данные проходят три стадии хранения. Регуляторные требования: betting data 5+ лет (Curaçao license).

- **Hot — 3 месяца**
  Storage: ClickHouse (primary SSD) Активные данные для daily operations, дашбордов, ad-hoc запросов. Максимальная скорость. Все mart-таблицы, свежие факты.
- **Warm — 1 год**
  Storage: ClickHouse (cold storage / HDD) Исторические данные для когортного анализа, YoY сравнений, ML-тренировок. Запросы медленнее, но доступны через тот же SQL.
- **Cold — 5+ лет**
  Storage: GCS (Parquet format) Архив для compliance и аудита. Регуляторные требования Curaçao: betting data хранится минимум 5 лет. Доступ через ad-hoc Spark/DuckDB job.

> *WARNING: PII retention: Player PII (email, phone, name) удаляется через 30 дней после запроса на удаление (GDPR). player_id остаётся для аналитики в анонимизированном виде.*

07. SLA

Service Level Agreements между data-командами. Кто кому что обещает, как измеряется и что делать при нарушении.

SLA Matrix

DE → Analytics

Service	SLA Metric	Target	Measurement	Escalation
Data freshness	Critical marts updated	By 07:00 UTC daily	Airflow sensor + Grafana	Lead DE → Director if > 09:00
Data completeness	NULL rate in required fields	> 99.5%	dbt tests (daily)	Slack #data-alerts → DE on-call
Mart availability	Critical mart downtime	< 2h / month	Uptime monitoring	P1 incident if CEO dashboard affected

DE → Data Science

Service	SLA Metric	Target	Measurement	Escalation
Feature Store	Feature freshness	Updated by 08:00 UTC	Feast monitoring	Lead DE + Lead DS
Training data	Data request fulfillment	Within 24h of request	Jira ticket tracking	Lead DE if > 48h

Analytics → Business

Service	SLA Metric	Target	Measurement	Escalation
Ad-hoc request	Time to deliver	3 business days	Jira ticket	Lead Analyst if > 5 days
Research	Time to deliver	2 weeks	Jira ticket	Director if blocked
New dashboard	Time to deliver	1 sprint (2 weeks)	Sprint board	Lead Analyst + Lead BI

DS → Product

Service	SLA Metric	Target	Measurement	Escalation
New model	Task to MVP	4-6 weeks	Jira epic	Lead DS → Director
Model retraining	Retraining cadence	Monthly	MLflow run history	Lead DS if drift detected
Fraud scoring	Inference latency	< 100ms p99	Grafana latency dashboard	P1 if > 500ms

BI → All

Service	SLA Metric	Target	Measurement	Escalation
Dashboard uptime	Critical dashboards availability	99.5%	Metabase health check	Lead BI + Platform DE
Dashboard load	Page load time	< 5 sec	Metabase query logs	BI Dev optimizes queries

Service	SLA Metric	Target	Measurement	Escalation
Data freshness in BI	Data lag after DWH update	≤ 1h	Metabase cache config	Lead BI if > 2h

Incident Severity Levels

Классификация инцидентов для SLA response time. Подробный протокол — в 11. Incident Response .

Level	Description	Acknowledge	Fix	Examples
P1 Critical	Critical mart/pipeline down, CEO report broken, fraud scoring offline	30 min	4h	mart_daily_kpi not updated, fraud model down
P2 High	Non-critical dashboard stale, DQ test failed on non-critical field	2h	24h	Marketing dashboard stale, NULL spike in optional field
P3 Medium	Minor DQ issue, documentation outdated, non-blocking request	1 business day	1 sprint	DataHub description outdated, minor schema drift

Как измеряется и отслеживается

Инструменты

- Grafana: дашборд SLA Compliance — % соблюдения по каждому SLA за rolling 30 days
- Airflow: SLA miss alerts — автоматический алерт при нарушении дедлайна DAG
- Jira: трекинг времени на ad-hoc и research requests
- Slack #data-alerts: все автоматические алерты приходят сюда

При нарушении SLA

- 1. Автоматический алерт → Slack #data-alerts + PagerDuty (P1)
- 2. On-call DE acknowledge → ставит статус «investigating» в Slack thread
- 3. Fix или workaround → уведомление потребителей
- 4. Post-mortem для P1/P2 (в течение 48 часов)
- 5. SLA review проводится ежемесячно в рамках одной из еженедельных встреч Director ↔ Leads

08. DataOps

Как код данных попадает в production, как мониторится здоровье пайплайнов, кто дежурит и как устроены среды разработки.

CI/CD for Data

Каждое изменение в dbt-моделях или пайплайнах проходит полный цикл: от feature branch до production.

- **1. Feature Branch**
  Разработчик создаёт ветку от develop . Именование: feature/DE-123-add-player-segment . Локальная разработка в dbt с dbt run --select model_name .
- **2. Pull Request**
  PR в develop . Автоматически запускается CI: dbt compile + dbt test на staging. Линтер SQL (sqlfluff). PR template: что изменено, почему, impact.
- **3. Code Review**
  Минимум 1 approve от Senior/Lead DE. Чеклист: соглашения по именованию, тесты покрывают новые поля, документация обновлена, нет ломающих изменений.
- **4. Merge → Staging**
  Merge в develop . Автоматический dbt run на staging. Проверка: данные в staging-дашборде корректны.
- **5. Release → Production**
  PR из develop в main . Release tag. dbt run на prod через Airflow. Мониторинг первые 24 часа: объём данных, DQ тесты, скорость запросов.
- **6. Monitoring**
  Grafana + Airflow SLA: свежесть данных, объём строк, время выполнения, DQ score. Алерты в Slack #data-alerts.

Git-flow

TEXT

```
main (prod)      ──────────────●──────────●──────────
                               ↑          ↑
develop (staging) ─●─●─●─┘─●─●─●─┘─●─●─
                     ↑  ↑  ↑    ↑  ↑  ↑
feature branches     └──┘──┘    └──┘──┘
```

Monitoring

Что мониторится, где алерты, как выглядит Data Health dashboard.

What	Tool	Alert Condition	Channel

What	Tool	Alert Condition	Channel
Data freshness	Airflow SLA sensor	Mart not updated by deadline	#data-alerts
Volume anomaly	Great Expectations	Row count deviates >20% from avg	#data-alerts
Schema changes	dbt schema tests	New/removed columns in source	#data-alerts
Query performance	ClickHouse system.query_log	Query >30s on critical mart	#de-performance
Infrastructure cost	GCP billing alerts	Daily cost >120% of budget	#finops
DQ test failures	dbt test + CI	Any test failure in production	#data-alerts + PagerDuty (P1)

Data Health Dashboard

Таблица marts × status. Обновляется каждые 15 минут. Доступен всем в Grafana.

Mart	Freshness	DQ Score	Status
mart_daily_kpi	06:45 UTC	99.2%	OK
mart_player_lifetime	06:52 UTC	98.8%	OK
mart_cohort_analysis	07:15 UTC	97.5%	OK
mart_marketing_performance	07:30 UTC	95.1%	WARN
mart_game_performance	08:45 UTC	91.3%	ALERT

On-call

DE on-call ротация: 1 неделя. Все DE и Platform Engineer участвуют (4 человека в ротации, каждый дежурит раз в месяц).

Runbook — типичные инциденты

Airflow DAG failed [P1/P2]

1. Открыть Airflow UI → найти failed task
2. Прочитать логи — определить root cause (OOM, timeout, source unavailable)
3. Retry задачи через UI (Clear → Run)
4. Если retry не помог → проверить source connectivity, ClickHouse health
5. Если не ясно → эскалация на Lead DE в Slack #data-incidents
6. После фикса: проверить данные в mart, уведомить потребителей

ClickHouse query timeout [P2]

1. Проверить system.query_log — какой запрос тормозит
2. Проверить system.merges — не идёт ли heavy merge
3. Kill проблемный запрос если блокирует других
4. Если проблема в модели — оптимизировать (добавить WHERE, PREWHERE, partitioning)
5. Если системная — эскалация на Platform Engineer

Source data delayed / missing [P2]

1. Проверить Airbyte sync status — последний успешный sync
2. Проверить source connectivity (может быть downtime у провайдера)
3. Если source down → уведомить потребителей о задержке, поставить ETA

4. Если Airbyte issue → restart sync, проверить логи коннектора
5. Если данные пришли частично → пометить в DQ dashboard, не давать уйти в mart

DQ test failure in production [P2/P3]

1. Определить severity: critical mart (P1) vs non-critical field (P3)
2. Проверить масштаб: сколько строк затронуто, с какого момента
3. Если данные уже в mart → откатить к последнему clean state если возможно
4. Root cause: изменение в source? Баг в dbt model? Schema drift?
5. Fix → re-run → verify → уведомить потребителей

Environments

Env	Purpose	Data	Access	Deploy
dev	Локальная разработка	Subset prod data (1 month, anonymized)	Каждый разработчик	dbt run --target dev
staging	Интеграционное тестирование	Full prod copy (refreshed weekly)	DE team + leads	Auto on merge to develop
prod	Production	Live data	Airflow service account only	Release PR develop → main

> *WARNING: Promote-правило: никакие изменения не попадают в prod без прохождения staging. Даже hotfix: создать branch от main , протестировать на staging, merge в main + cherry-pick в develop .*

09. MLOps

Как ML-модели проходят путь от гипотезы до production: lifecycle, эксперименты, Feature Store, мониторинг и три model cards.

Эта страница описывает

ML-платформы Fantasy iGaming. Текущий прогресс внедрения — в разделе

.

ML Lifecycle

Каждая модель проходит полный цикл. Не все задачи требуют ML — если эвристика решает проблему, модель не нужна. Подробнее о стеке — в 01. Data Architecture .

- **1. Постановка задачи**
  Lead DS + Product определяют: какую бизнес-задачу решаем, какая метрика успеха, есть ли данные, оправдан ли ML (vs эвристика). Результат: ML Design Doc.
- **2. Подготовка данных**
  DS совместно с DE: выбор фичей, создание training dataset, feature engineering. Фичи регистрируются в Feature Store (Feast). Проверка качества: нет утечки данных (data leakage), корректное разделение train/test.
- **3. Обучение**
  Эксперименты в Jupyter, трекинг в MLflow: параметры, метрики, артефакты. Сравнение подходов: baseline (эвристика) → простая модель → сложная модель. Выбор по метрике + интерпретируемости.
- **4. Валидация**
  Оценка на hold-out и кросс-валидация. Проверка на смещения (bias): по гео, сегментам, VIP-тирам. Lead DS ревьюит результаты и методологию.
- **5. Деплой**
  ML Engineer упаковывает модель: Docker-контейнер + REST API (для real-time) или batch-скрипт (для offline scoring). Модель регистрируется в Model Registry: staging → production.
- **6. Мониторинг**
  Отслеживание в production: model drift (PSI), data drift (распределение входных фичей), бизнес-метрики vs baseline. Алерты при деградации.
- **7. Переобучение**
  По расписанию (monthly) или по триггеру (drift alert). Новая версия проходит валидацию → staging → production. Старая версия архивируется.

Experiment Tracking (MLflow)

Каждый эксперимент логируется в MLflow: параметры, метрики, артефакты. Воспроизводимость гарантирована — любой run можно повторить.

Пример записи эксперимента

Experiment	ltv_prediction_v3
Run ID	run_2026-03-12_14-30
Алгоритм	LightGBM
Параметры	n_estimators=500, max_depth=8, learning_rate=0.05, min_child_samples=50
Фичи	47 (из Feature Store)
Training set	120K игроков, когорты Jan 2025 — Dec 2025
Метрики	MAE: $42.3, MAPE: 18.7%, R^2: 0.72
Артефакты	model.pkl, feature_importance.png, confusion_matrix.png
Статус	promoted to staging

Model Registry

Реестр версий моделей. Каждая модель проходит стадии: staging → production → archived.

Модель	Версия	Стадия	Дата	Метрика
ltv_prediction	v1.2	production	2026-03-15	MAE: $42.3
ltv_prediction	v1.3	staging	2026-04-01	MAE: $39.8
ltv_prediction	v1.1	archived	2026-02-10	MAE: $48.1
churn_prediction	v2.0	production	2026-03-01	AUC: 0.84
fraud_detection	v3.1	production	2026-02-20	AUC: 0.91

Процесс промоушена

- DS обучает и валидирует → коммитит в MLflow
- Lead DS ревьюит: метрики, bias check, методологию
- ML Engineer деплоит на staging → нагрузочное тестирование
- Ок → промоушен в production, старая версия в archived

Feature Store (Feast)

Единый реестр фичей для ML. Offline store (для обучения, ClickHouse) + online store (для real-time inference, Redis). Одна фича — один источник правды.

Пример фичи: player_avg_bet_7d

Имя	player_avg_bet_7d
Описание	Средняя сумма ставки игрока за последние 7 дней
Entity	player_id
Тип	Float64
Источник	int_bets_enriched (агрегация по player_id, window 7 days)
Обновление	Daily, к 08:00 UTC (после обновления mart)
Потребители	LTV model, Churn model, Fraud model
Online latency	< 5ms (Redis)

PYTHON

```
# Получение фичей для prediction
from feast import FeatureStore

store = FeatureStore(repo_path="feature_repo/")

features = store.get_online_features(
    features=[
        "player_features:avg_bet_7d",
        "player_features:total_deposits_30d",
        "player_features:days_since_last_bet",
        "player_features:session_count_7d",
    ],
    entity_rows=[{"player_id": "usr_28491"}],
).to_dict()
```

Мониторинг моделей

Три типа мониторинга в production: дрифт модели, дрифт данных, бизнес-метрики.

Тип	Что измеряем	Метрика	Порог алерта	Действие
Model drift	Изменение распределения предсказаний	PSI (Population Stability Index)	PSI > 0.2	Переобучение
Data drift	Изменение распределения входных фичей	KS-test по каждой фиче	p-value < 0.01 для >3 фичей	Исследование + возможное переобучение
Бизнес-метрики	Совпадение предсказаний с реальностью	MAE, AUC, precision/recall vs baseline	Деградация >10% от baseline	Срочное переобучение

Model Cards

LTV

LTV Prediction [production]

Задача	Прогноз lifetime NGR игрока на горизонте 12 месяцев
Целевая переменная	lifetime_ngr_12m (непрерывная, USD)
Алгоритм	LightGBM (gradient boosting)
Метрики	MAE: $42.3, MAPE: 18.7%, R^2: 0.72
Переобучение	Ежемесячно (1-е число)
SLA	Scoring batch: к 09:00 UTC ежедневно

Топ-10 фичей

- total_deposits_30d — сумма депозитов за 30 дней
- avg_bet_7d — средняя ставка за 7 дней
- days_since_registration — возраст аккаунта
- session_count_7d — количество сессий за 7 дней
- deposit_frequency_30d — частота депозитов

- product_mix — casino vs sports (доля)
- geo — страна
- acquisition_channel — канал привлечения
- bonus_usage_rate — доля бонусных ставок
- avg_session_duration_7d — средняя длительность сессии

> *INFO: Использование: маркетинг (определение бюджета по каналам), CRM (сегментация по прогнозируемой ценности), Product (приоритизация фичей для high-LTV сегмента).*

Churn

Churn Prediction [production]

Задача	Вероятность ухода игрока в течение 30 дней
Целевая переменная	is_churned_30d (бинарная: 0/1)
Алгоритм	LightGBM (classification)
Метрики	AUC: 0.84, Precision@top10%: 0.62, Recall@top10%: 0.41
Переобучение	Ежемесячно
SLA	Scoring batch: к 09:00 UTC ежедневно

Trade-off: precision vs recall

Для churn-модели важнее precision в верхнем дециле : мы хотим, чтобы из топ-10% «рискованных» большинство действительно ушли. Высокий recall менее критичен — лучше точно определить 40% churners, чем «поймать всех» с кучей false positives (лишние бонусы = лишние расходы).

> *TIP: Интеграция: churn_score → Census (Reverse ETL) → CRM segment «at risk» → персонализированный бонус или push-уведомление. Замкнутый цикл: данные → модель → действие → результат.*

Fraud

Fraud Detection [production — real-time]

Задача	Real-time скоринг транзакций на фрод (мульти-аккаунты, бонус-абьюз, коллюзия)
Целевая переменная	is_fraud (бинарная), fraud_score (0.0–1.0)
Алгоритм	LightGBM + rule-based engine (гибрид)
Метрики	AUC: 0.91, FPR: 3.2%, Precision: 0.78, Recall: 0.65
Переобучение	Еженедельно (фрод-паттерны меняются быстро)
SLA	Latency: < 100ms p99, доступность: 99.9%

Архитектура

Real-time scoring через REST API (Docker + FastAPI). Фичи из online Feature Store (Redis, < 5ms). При fraud_score > 0.8 транзакция блокируется автоматически. При 0.5–0.8 — отправляется на ручную проверку в Risk-команду.

> *WARNING: FPR критичен: каждый false positive — это легитимный игрок, которому*

заблокировали транзакцию. При FPR 3.2% на 100K транзакций/день = ~3,200 ложных блокировок. Цель: FPR < 5%, оптимально < 2%.

Утилизация моделей: от score к бизнес-действию

Модель в production бесполезна, если её output не приводит к конкретному действию. Для каждой из трёх моделей — как именно score превращается в бизнес-результат.

LTV Utilization

LTV Prediction — утилизация

pLTV сегмент	Порог	Действие	Исполнитель
High LTV (>$500)	top 15%	Увеличить bid в paid каналах, приоритет в VIP-программе, персональный менеджер	Marketing + VIP team
Medium LTV ($100–500)	middle 60%	Стандартная CRM-коммуникация, стандартные бонусы	CRM автоматически
Low LTV (<$100)	bottom 25%	Снизить маркетинговый бюджет на канал, не давать крупные бонусы	Marketing

Пример

Канал Facebook CIS показывает средний pLTV = $85 при CAC = $60. LTV:CAC = 1.4 — ниже порога 3.0. Решение: снизить бюджет на 50%, перераспределить в пользу Organic Search (pLTV = $320, CAC ≈ $0). Ожидаемый эффект: общий blended LTV:CAC вырастет с 2.8 до 3.5.

Churn Utilization

Churn Prediction — утилизация

Churn risk	Порог score	Действие	Канал	Timing
Critical	> 0.8	Персональный звонок от VIP-менеджера (для VIP) или крупный cashback	Телефон / email	В течение 24ч
High	0.6–0.8	Персонализированный бонус: фрибет на любимый спорт или фриспины на любимый слот	Push / email	В течение 48ч
Medium	0.4–0.6	Стандартная реактивация: общий бонус + напоминание о предстоящих матчах	Email	В течение 72ч
Low	< 0.4	Ничего — не тратить ресурсы, игрок активен	—	—

Пример

Игрок usr_28491 , сегмент regular, churn_score = 0.73. Последняя ставка 12 дней назад. Любимый спорт — футбол. CRM автоматически отправляет push: «Финал Лиги Чемпионов через 3 дня — вот фрибет $10 на любой исход». Retention rate в этом сегменте после такой

кампании: +18%.

Fraud Utilization

Fraud Detection — утилизация

Fraud score	Порог	Действие	Автоматизация
Block	> 0.8	Транзакция заблокирована, аккаунт flagged для расследования	Полностью автоматически
Review	0.5–0.8	Транзакция на hold, уходит в очередь Risk-команды	Авто-hold, ручной review
Pass	< 0.5	Транзакция проходит, логируется для обучения модели	Автоматически

Пример

Новый аккаунт, зарегистрирован 2 часа назад. Первый депозит $500 (в 5x выше среднего FTD). IP совпадает с 3 другими аккаунтами. fraud_score = 0.87. Автоматическая блокировка транзакции. Risk-команда проверяет — подтверждённый мульти-аккаунт. Все связанные аккаунты заблокированы.

> *TIP: Пороги — не константа. Их калибруют ежеквартально на основе precision/recall trade-off и бизнес-стоимости ошибок. False positive в fraud = потеря легитимного игрока ($200+ LTV). False negative = фрод-потери ($50–500 per case). Баланс пересматривается на Governance Council.*

10. Data Lineage

Полный путь данных от источника до потребителя. Три примера: NGR lineage, LTV calculation, Churn prediction pipeline.

Data lineage отвечает на вопрос: «откуда взялось это число в дашборде?». Каждый шаг — инструмент, владелец и DQ-проверки. Подробнее о стеке — в

.

Пример 1: путь NGR от ставки до дашборда CEO

Полный end-to-end: игрок делает ставку → данные проходят 8 этапов → CEO видит NGR на утреннем дашборде.

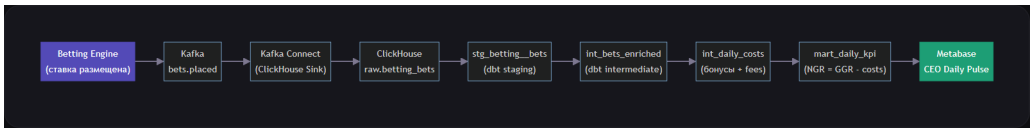

Per-step annotations

Betting Engine → Kafka [источник]

Что происходит	**Игрок размещает ставку. Бэкенд записывает событие bets.placed в Kafka topic.**
Инструмент	Apache Kafka (event streaming)
Владелец	Backend-команда
DQ-проверки	Schema validation на уровне producer (Avro schema registry)
Latency	Миллисекунды

Kafka → ClickHouse raw [ingestion]

Что происходит	**Kafka Connect (ClickHouse Sink) читает из Kafka и загружает в raw.betting_bets таблицу ClickHouse. Streaming с минимальной задержкой.**
Инструмент	Kafka Connect (ClickHouse Sink)
Владелец	Data Engineering
DQ-проверки	Мониторинг объёма: алерт если row count отклоняется > 20% от среднего

raw → stg_betting__bets [dbt staging]

Что происходит	**Очистка: приведение типов, lower(status), дедупликация по bet_id, фильтрация NULL.**
Инструмент	dbt Core (SQL model)

Что происходит	**Очистка: приведение типов, lower(status), дедупликация по bet_id, фильтрация NULL.**
Владелец	Analytics Engineer
DQ-проверки	unique(bet_id) , not_null(bet_id, player_id, bet_amount)

stg → int_bets_enriched [dbt intermediate]

Что происходит	**Обогащение: JOIN с dim_players (geo, segment) и dim_games (provider, game_type). Расчёт GGR = bet_amount - payout_amount.**
Инструмент	dbt Core
Владелец	Analytics Engineer
DQ-проверки	relationships(player_id → dim_players) , accepted_values(product, ['casino','sports'])

int → mart_daily_kpi [dbt mart]

Что происходит	**Агрегация по дням: SUM(GGR), вычет бонусов и комиссий из int_daily_costs. Финальная формула: NGR = GGR - bonus_cost - provider_fees - payment_fees.**
Инструмент	dbt Core
Владелец	Financial Analyst (steward), CFO (data owner)
DQ-проверки	Consistency: SUM(fct_bets.amount) = mart_daily_kpi.turnover ±0.01%. Freshness: обновление к 07:00 UTC.

mart → Metabase (CEO Daily Pulse) [BI]

Что происходит	**Metabase запрашивает mart_daily_kpi и отображает: NGR, GGR, Active Players, Deposits. Sparklines WoW, разбивка по гео.**
Инструмент	Metabase (self-hosted)
Владелец	BI Engineering
DQ-проверки	Dashboard load time < 5 сек. Данные не старше 1 часа после обновления DWH.
Потребитель	CEO, CFO, C-level (ежедневный утренний обзор)

Пример 2: как считается LTV игрока

Более универсальный пример — LTV как метрику считают в любом бизнесе, не только в iGaming. Полный путь: от сырых транзакций до решения «масштабировать канал или отключить».

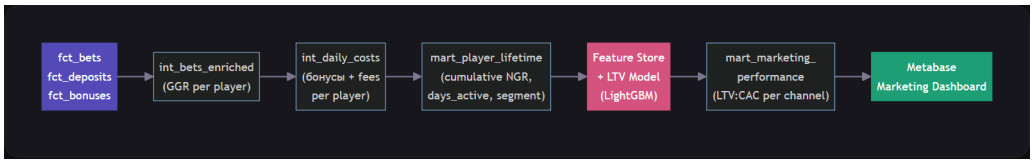

fct_bets + fct_deposits + fct_bonuses [источники]

Что происходит	**Три факт-таблицы содержат все транзакции игрока: ставки (суммы, продукт, результат), депозиты (суммы, метод, FTD-флаг) и бонусы (тип, сумма, статус отыгрыша).**
Инструмент	ClickHouse (DWH)
Владелец	Data Engineering
DQ-проверки	unique(bet_id) , unique(deposit_id) , unique(bonus_id) . Полнота: NULL rate < 1% в ключевых полях.

int_bets_enriched → int_daily_costs [dbt intermediate]

Что происходит	**int_bets_enriched рассчитывает GGR per player (bet_amount - payout_amount). int_daily_costs агрегирует бонусные расходы и комиссии провайдеров/платёжных систем per player per day.**
Инструмент	dbt Core
Владелец	Analytics Engineer
DQ-проверки	Consistency: SUM(ggr) по int_bets_enriched = SUM(ggr) по mart_daily_kpi за тот же период (±0.01%)

mart_player_lifetime [dbt mart]

Что происходит	**Cumulative метрики по каждому игроку: lifetime_ngr (= GGR - bonus_cost - fees), days_active, total_bets, segment. Это фактический (когортный) LTV — то, сколько игрок уже принёс.**
Инструмент	dbt Core
Владелец	Financial Analyst (steward)
DQ-проверки	not_null(player_id, lifetime_ngr) . Бизнес-правило: lifetime_ngr не может быть отрицательным для когорт старше 6 месяцев (если да — аномалия).

Feature Store + LTV Model [ML]

Что происходит	**Фичи из Feast (avg_bet_7d, deposit_frequency, session_count и др.) подаются в LightGBM-модель. На выходе — прогнозный LTV на 12 месяцев. Batch scoring ежедневно к 09:00 UTC.**
Инструмент	Feast (Feature Store) + LightGBM + MLflow

Что происходит	**Фичи из Feast (avg_bet_7d, deposit_frequency, session_count и др.) подаются в LightGBM-модель. На выходе — прогнозный LTV на 12 месяцев. Batch scoring ежедневно к 09:00 UTC.**
Владелец	Data Science
DQ-проверки	Model drift: PSI < 0.2. Бизнес-check: средний predicted LTV не отклоняется > 20% от когортного LTV за тот же период.

mart_marketing_performance [dbt mart]

Что происходит	**Predicted LTV агрегируется по каналам и кампаниям. Рассчитывается LTV:CAC ratio = avg(predicted_ltv) / CAC. Это ключевая метрика для решений по маркетинговому бюджету.**
Инструмент	dbt Core
Владелец	Marketing Analyst (steward), CMO (data owner)
DQ-проверки	LTV:CAC не может быть отрицательным. Алерт если LTV:CAC < 1.0 для канала с spend > $10K/мес.

Metabase Marketing Dashboard [BI]

Что происходит	**CMO и маркетинг-команда видят LTV:CAC по каналам, ROAS, тренды. Решение: масштабировать канал (LTV:CAC > 3), оптимизировать (2-3) или отключить (< 1.5).**
Инструмент	Metabase
Владелец	BI Engineering
DQ-проверки	Данные не старше 24 часов. Dashboard load < 5 сек.
Потребитель	CMO, Marketing Analysts, Growth-команда

> *TIP: LTV — прогноз, не факт. Когортный LTV (фактический) считается из mart_player_lifetime. Прогнозный LTV — из ML-модели. Маркетинг использует прогнозный для быстрых решений, финансы — когортный для отчётности. Оба должны сходиться на горизонте 6+ месяцев, иначе модель врёт.*

Пример 3: Churn Prediction Pipeline

Более короткий пример: от факт-таблиц до персонализированного бонуса в CRM.

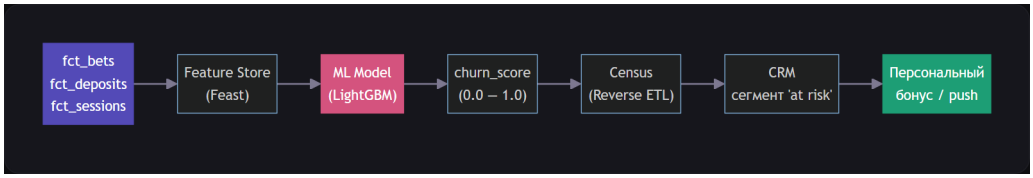

Этап	Инструмент	Владелец	Описание
Факт-таблицы	ClickHouse	DE	fct_bets, fct_deposits, fct_sessions — сырые данные о поведении игрока
Feature Store	Feast	DS + DE	Агрегированные фичи: avg_bet_7d, days_since_last_bet, deposit_frequency и др.
ML-модель	LightGBM + MLflow	Data Science	Batch scoring: каждый игрок получает churn_score от 0 до 1. Ежедневно к 09:00.
Reverse ETL	Census	DE	churn_score отправляется из ClickHouse в CRM. Sync каждые 2 часа.
CRM-действие	CRM	CRM / Marketing	Игроки с score > 0.7 попадают в сегмент «at risk». Автоматический триггер: персональный бонус или push-уведомление.

> *TIP: Замкнутый цикл: данные → модель → действие → результат → данные. Если бонус сработал и игрок остался — это новые данные для следующего переобучения модели.*

11. Incident Response

Что делать, когда данные сломались. Severity levels, протокол от обнаружения до post-mortem, и реальный пример инцидента.

Severity Levels

Level	Criteria	Acknowledge	Fix	Post-mortem
P1 Critical	Critical mart down, CEO report broken, fraud scoring offline, data loss	30 min	4h	Required (within 48h)
P2 High	Non-critical dashboard stale, DQ failure on important field, partial data loss	2h	24h	Required (within 1 week)
P3 Medium	Minor DQ issue, docs outdated, non-critical pipeline delay, cosmetic bug	1 business day	1 sprint	Optional

> *INFO: Severity определяется по impact , не по root cause. Сломанный staging — P3. Тот же баг в prod, если ломает CEO dashboard — P1.*

Response Protocol

- **1. Detect**
  Автоматический алерт (Airflow, dbt test, Grafana) → Slack #data-alerts. Или ручное обнаружение (стейкхолдер сообщает о проблеме).
- **2. Acknowledge**
  On-call DE реагирует в thread: «investigating, ETA 30 min». Назначает severity. P1 → создаёт Slack channel #incident-YYYY-MM-DD , подключает Lead DE.
- **3. Diagnose**
  Root cause analysis: логи Airflow, ClickHouse system tables, dbt test output, source connectivity. Документирует findings в incident thread.
- **4. Fix**
  Применить fix или workaround. Приоритет: восстановить данные для потребителей. Re-run пайплайн, verify данные в mart. Hotfix через expedited PR если нужно.
- **5. Communicate**
  Уведомить стейкхолдеров: что сломалось, когда починили, есть ли data gap. Для P1: сообщение в #general и email affected stakeholders.
- **6. Post-mortem**
  Post-mortem без поиска виноватых — в Confluence. Хронология инцидента, корневая причина, что сработало хорошо, что пошло не так, action items с ответственным и дедлайном. Разбор на еженедельном командном синке.

Post-mortem — заполненный пример

mart_daily_kpi Update Failure — Champions League Final

Date	2026-06-01 (Monday)
Severity	P1
Duration	2h 15min (07:00 — 09:15 UTC)
Impact	CEO daily pulse dashboard показывал данные за субботу. Выходные цифры отсутствовали. CFO и CMO получили incorrect weekly summary.

Timeline

- **05:00 — DAG started**
  daily_pipeline DAG запустился по расписанию.
- **05:47 — Task OOM killed**
  Задача load_to_clickhouse убита по OOM (превышен лимит памяти 4GB). Данные за воскресенье после финала Лиги чемпионов: объём ставок в 3 раза выше обычного.
- **05:52 — Auto-retry #1**
  Airflow retry #1 — тоже OOM killed.
- **06:02 — Auto-retry #2**
  Retry #2 — OOM killed. DAG marked as failed.
- **07:00 — SLA alert**
  Airflow SLA sensor: mart_daily_kpi не обновлён к 07:00. Алерт → #data-alerts + PagerDuty.
- **07:12 — Acknowledged**
  On-call DE (Иван) acknowledged. Начал investigation.
- **07:30 — CEO reports issue**
  CEO в #general: «Цифры за выходные выглядят неправильно». Lead DE подключился к incident channel.
- **07:45 — Root cause found**
  OOM из-за всплеска данных после финала Лиги чемпионов. Память воркера 4GB, нужно 8GB+.
- **08:10 — Fix applied**
  Увеличена память воркера до 12GB. Добавлена batch-обработка (партиционирование по часам вместо полного дня).
- **09:00 — Pipeline re-run complete**
  Данные за субботу и воскресенье загружены. mart_daily_kpi обновлён.
- **09:15 — Resolved**
  Дашборд CEO проверен. Стейкхолдеры оповещены. Инцидент закрыт.

Корневая причина

Лимит памяти воркера Airflow (4GB) оказался недостаточным для всплеска данных после финала Лиги чемпионов. Объём ставок в воскресенье был в 3,2 раза выше нормы. Задача load_to_clickhouse загружает полный день одним батчем — OOM при большом объёме.

Что сработало хорошо

- SLA alert сработал вовремя (07:00)
- On-call DE ответил в течение 12 минут
- Root cause найден за 33 минуты
- Данные полностью восстановлены, без потерь

Что пошло не так

- Нет отдельного алерта на OOM — пришёл только generic SLA miss в 07:00, а не в 05:47 при первом OOM
- Нет autoscaling — статичный лимит памяти не справился со всплеском
- Retry потратили время впустую — та же конфигурация, тот же результат
- CEO обнаружил проблему раньше, чем команда успела оповестить

Action Items

Действие	Ответственный	Дедлайн
Добавить OOM-алерт (Grafana при memory воркера >80%)	Platform DE	2026-06-06
Внедрить batch-обработку по часам вместо полного дня	DE Lead	2026-06-09
Настроить autoscaling воркеров Airflow (KEDA)	Platform DE	2026-06-16
Планирование ёмкости перед крупными спортивными событиями	DE Lead + Product	2026-06-20
Проактивное оповещение стейкхолдеров (до того как спросят)	Director	2026-06-09

12. Dashboard Mockups

6 мокапов ключевых дашбордов с фейковыми данными. Каждый выглядит как реальный BI-отчёт: sparklines, bar charts, heatmaps — чистый CSS + inline SVG.

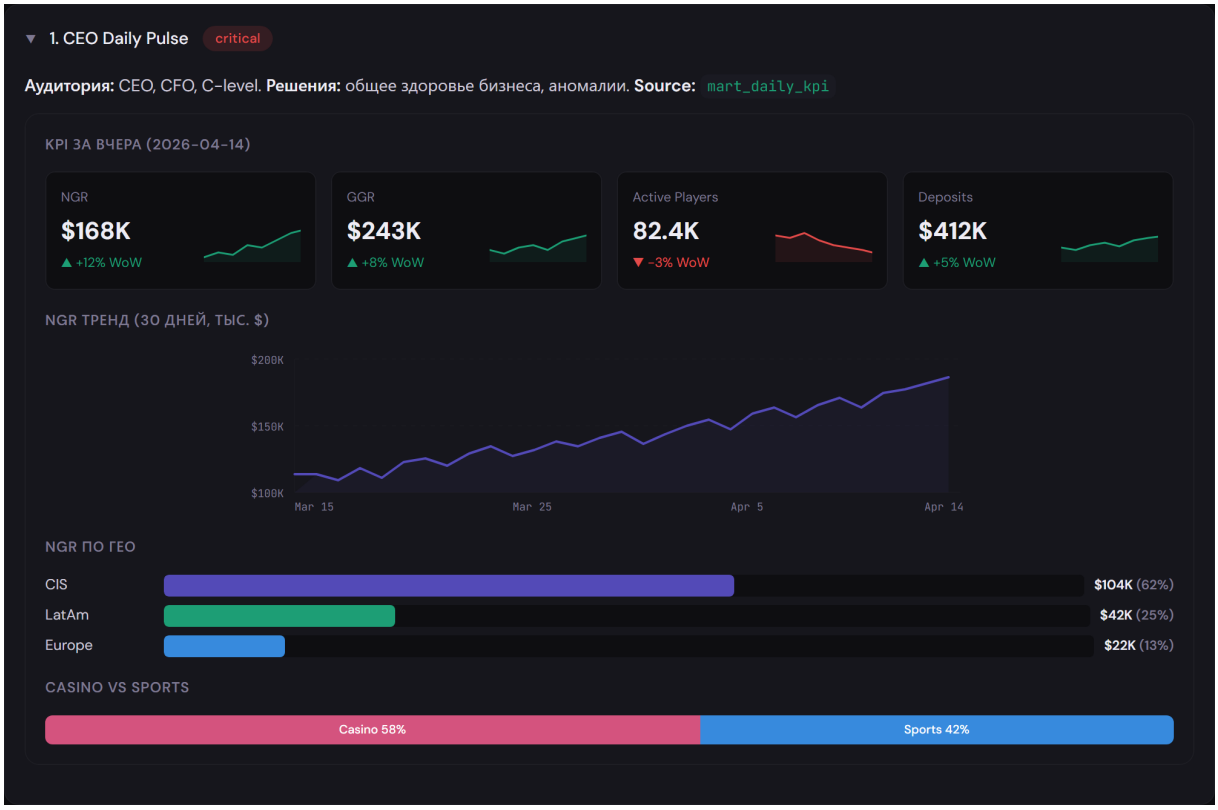

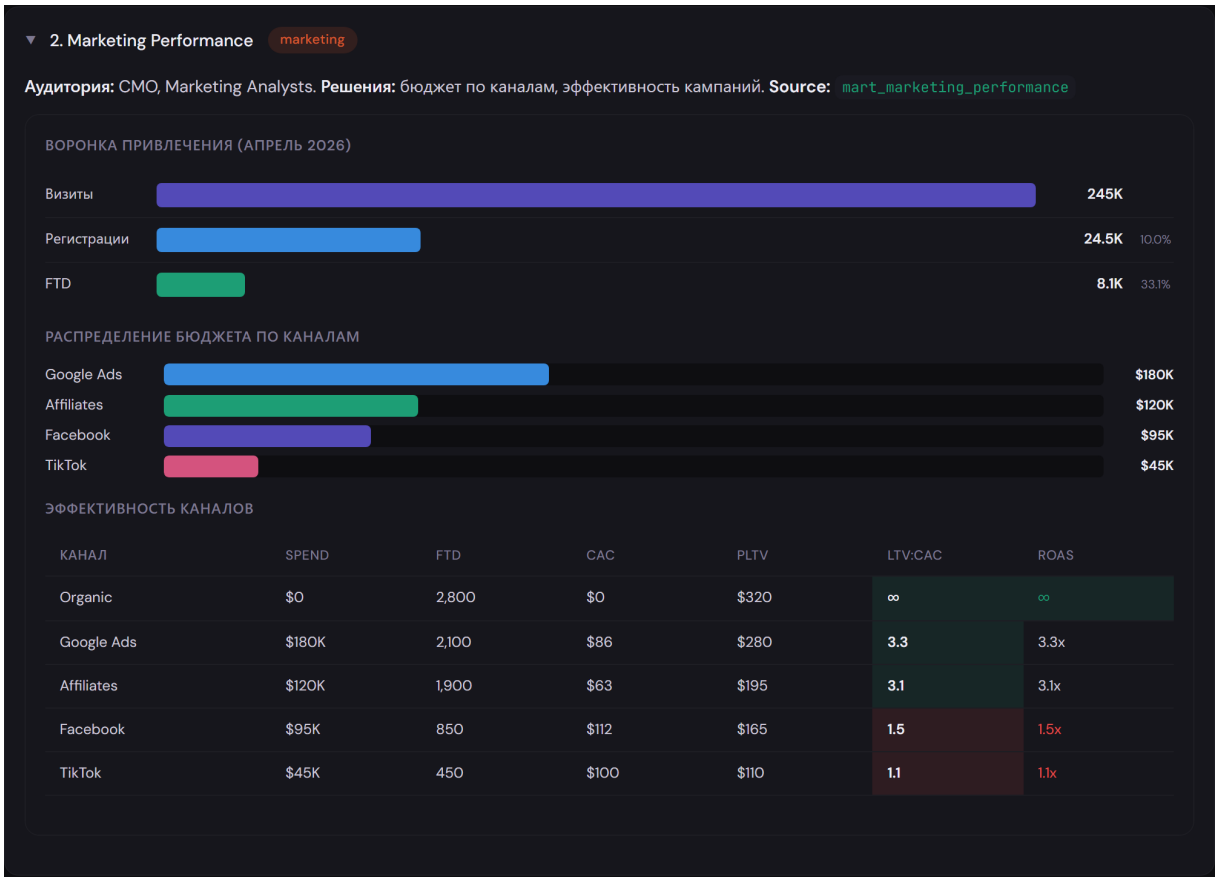

3. Casino Product [product]

Аудитория: PM Casino. Решения: провайдерский микс, отклонения RTP, топ-игры. Source: mart_game_performance

GGR by provider (horizontal bars)

GGR по провайдерам (апрель)

Game type donut

Разбивка по типам игр

$278K

Slots — 65% ($181K)

Live — 25% ($69K)

Table — 10% ($28K)

Top 10 games with RTP conditional formatting

Топ-10 игр по GGR

Игра	Провайдер	Тип	GGR	RTP теор.	RTP факт.	Статус
Sweet Bonanza	Pragmatic	slot	$18.2K	96.50%	96.12%	OK
Crazy Time	Evolution	live	$15.8K	95.50%	95.23%	OK
Gates of Olympus	Pragmatic	slot	$12.1K	96.50%	97.82%	RTP+

Игра	Провайдер	Тип	GGR	RTP теор.	RTP факт.	Статус
Lightning Roulette	Evolution	live	$9.7K	97.30%	97.05%	OK
Book of Dead	Play'n GO	slot	$8.4K	96.20%	95.81%	OK
Big Bass Bonanza	Pragmatic	slot	$7.9K	96.71%	96.55%	OK
Monopoly Live	Evolution	live	$6.3K	96.23%	98.41%	RTP!!
Starburst	NetEnt	slot	$5.8K	96.10%	96.02%	OK
Aviator	Spribe	crash	$5.2K	97.00%	96.88%	OK
Reactoonz	Play'n GO	slot	$4.5K	96.51%	96.30%	OK

4. Sports Product [product]

Аудитория: PM Sports. Решения: маржинальность по лигам, баланс pre-match vs live. Source: mart_daily_kpi (sports slice)

Handle by league

Handle по лигам (апрель)

Pre-match vs Live

Pre-match vs Live

Pre-match 62%

Live 38%

Live доля растёт: +5pp vs прошлый месяц. Тренд на увеличение live-ставок — типичный для зрелых рынков.

Margin trend sparkline

Маржа % (30 дней)

Средняя маржа

8.2%

+0.3pp MoM

▼ 5. Cohort Analysis analytics

Аудитория: Product, Marketing, DS. **Решения:** качество когорт, retention деградация, LTV-оценка. **Source:** `mart_cohort_analysis`

RETENTION HEATMAP (% АКТИВНЫХ)

КОГОРТА	N	M0	M1	M2	M3	M4	M5	M6
Oct '25	8.2K	100%	38%	24%	18%	15%	13%	12%
Nov '25	9.1K	100%	42%	26%	19%	16%	14%	
Dec '25	11.5K	100%	35%	21%	16%	13%		
Jan '26	7.8K	100%	44%	28%	20%			
Feb '26	8.6K	100%	40%	25%				
Mar '26	9.4K	100%	39%					

CUMULATIVE NGR ПО КОГОРТАМ (ТЫС. $)

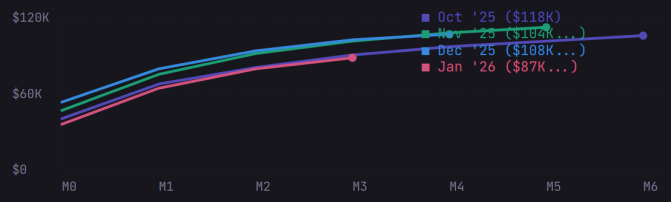

6. Data Health [operations]

Аудитория: DE team, Director of Data. Решения: состояние пайплайнов, приоритизация инцидентов. Source: Airflow, dbt tests, Grafana

KPIs

Обзор за текущий месяц

DQ Score

96.4%

+1.2pp

SLA Compliance

97.8%

стабильно

P1 инцидентов

было 0 в прошлом

Открытые P2/P3

3

норма

Mart status table

Статус mart-таблиц

Mart	Обновлён	DQ Score	Статус	Инциденты
mart_daily_kpi	06:45 UTC	99.2%	OK	—
mart_player_lifetime	06:52 UTC	98.8%	OK	—
mart_cohort_analysis	07:15 UTC	97.5%	OK	—
mart_marketing_performance	07:30 UTC	95.1%	WARN	P3 NULL spike в utm_campaign
mart_game_performance	08:45 UTC	91.3%	ALERT	P2 задержка провайдера

SLA Compliance bar chart

SLA Compliance по неделям

W1

W2

W3

W4

13. A/B Testing Framework

Как устроена экспериментальная платформа: от гипотезы до решения. HADI-цикл, бэклог, чеклист, шаблон отчёта и полный кейс с конкретными числами.

HADI-цикл

Каждый эксперимент проходит четыре фазы. Цикл повторяется: инсайт из одного теста порождает гипотезу для следующего.

- **H — Hypothesis (гипотеза)**
  Формулируем: «Если [изменение], то [метрика] [направление] на [MDE], потому что [обоснование]». Гипотеза должна быть конкретной, измеримой и фальсифицируемой.
- **A — Action (действие)**
  Реализуем изменение, настраиваем эксперимент: рандомизация, split, длительность. Проверяем чеклист запуска (см. ниже). Запускаем тест.
- **D — Data (данные)**
  Собираем данные за расчётный период. Не подглядываем до окончания (no-peek commitment). Проверяем SRM (Sample Ratio Mismatch) — split 50/50 ±1%.
- **I — Insight (инсайт)**
  Анализируем результаты: CI, p-value, effect size. Сегментация по гео, платформе, сегменту. Решение: раскатить / итерировать / закрыть. Документируем learning.

Бэклог гипотез

Все гипотезы приоритизированы по ICE: Impact × Confidence × Ease (каждый 1-10).

ID	Гипотеза	Метрика	MDE	ICE	Статус	Owner
AB-01	Если упростить форму депозита (3 поля → 1), то конверсия Reg→FTD вырастет на 15%, потому что снижается friction	Reg→FTD %	+15%	720	done	PM Payments
AB-02	Если показать персональные рекомендации игр на главной, то session duration вырастет на 10%	Avg session, мин	+10%	540	running	PM Casino
AB-03	Если заменить welcome bonus $20 freebet на $10 cashback, то LTV 30d вырастет на 8%, потому что cashback удерживает лучше	LTV 30d	+8%	480	backlog	CRM Lead
AB-04	Если добавить live-стриминг на страницу матча, то handle на live-ставки вырастет на 20%	Live handle	+20%	420	backlog	PM Sports
AB-05	Если отправлять push-уведомление за 1 час до матча (вместо 24ч), то CTR push вырастет на 30%	Push CTR	+30%	360	backlog	CRM
AB-06	Если скрыть вейджер-требования при выдаче бонуса (показать только при попытке вывода), то bonus take rate вырастет на 25%	Bonus take				

rate

+25%	280	reject ed	Comp liance

WARNING: AB-06 отклонён: Compliance заблокировал — скрытие условий бонуса нарушает требования регулятора (Curaçao). Гипотеза переформулирована: «упростить отображение вейджера» вместо «скрыть».

Чеклист запуска

8 пунктов, которые должны быть выполнены до запуска любого A/B-теста.

- 1. Гипотеза — сформулирована в формате «если [X], то [Y] на [Z]%, потому что [причина]»
- 2. Метрики — определены primary (одна), secondary (1-3) и guardrail (что не должно упасть)
- 3. Sample size — рассчитан: MDE, power 80%, significance 95%. Калькулятор или формула в тикете
- 4. Рандомизация — на уровне player_id (не session). Проверен SRM на первые 24ч
- 5. Длительность — минимум 7 дней (полный недельный цикл). Для sports — минимум 14 дней (покрытие выходных матчей)
- 6. Stakeholder sign-off — PM + Lead DS + Lead Analyst подписали. Для тестов с бонусами — ещё и CFO
- 7. No-peek commitment — не смотреть результаты до окончания расчётного периода. Исключение: guardrail metric пробита — останавливаем
- 8. Rollback plan — что делать если тест ломает UX или метрику. Feature flag для мгновенного отключения

Сколько нужно данных для теста?

Формула расчёта sample size для двух пропорций (конверсии):

n = (Z

+ Z

$)^2 \times (p_1(1-p_1) + p_2(1-p_2)) / (p_2 - p_1)^2$

Где $\alpha = 0.05$ (significance), $\beta = 0.20$ (power 80%), p_1 = baseline, p_2 = baseline + MDE.

Готовая таблица для типичных iGaming-метрик

Метрика	Baseline	MDE	Target	Sample / group	Дней при 5K DAU
Reg → FTD	33%	+15%	38%	1,800	1 день
Visit → Reg	8%	+20%	9.6%	12,500	5 дней
Retention D7	18%	+10%	19.8%	35,000	14 дней
GGR per user	$12	+8%	$12.96	8,200	4 дня
Bonus take rate	45%	+10%	49.5%	2,100	1 день

TIP: Правило: чем меньше MDE хочешь поймать, тем больше данных нужно. Для конверсий ниже 5% тесты могут занимать недели. Если тест требует > 30 дней — подумайте, достаточно ли он ценен или можно увеличить MDE.

Шаблон отчёта

Структура

- Гипотеза: что тестировали и почему

- Setup: sample size, длительность, split, рандомизация
- Результат: primary metric — CI, p-value, effect size. Secondary и guardrail метрики
- Сегментация: результат по гео, платформе, VIP-тиру, каналу привлечения
- Рекомендация: раскатить на 100% / итерировать / закрыть — с обоснованием
- Learnings: что узнали, что можно протестировать следующим

Полный кейс: упрощение формы депозита (AB-01)

Гипотеза и расчёт

Гипотеза: если упростить форму первого депозита с 3 шагов (выбор метода → ввод суммы → подтверждение) до 1 шага (метод + сумма на одном экране), то конверсия Reg→FTD вырастет на 15%, потому что каждый лишний шаг теряет ~10% пользователей.

Primary metric: Reg→FTD conversion rate (текущий baseline: 33%)

Secondary: avg first deposit amount, time-to-deposit

Guardrail: payment failure rate не должна вырасти > 1pp

Baseline conversion	**33%**
MDE (minimum detectable effect)	+15% relative (33% → 38%)
Significance level (α)	0.05
Power (1-β)	0.80
Sample size per group	1,800 регистраций
Ожидаемые регистрации/день	~820
Длительность	5 дней (но округляем до 7 — полный недельный цикл)
Split	50/50 по player_id

Результаты

Метрика	**Control**	**Treatment**	**Δ**	**p-value**	**CI 95%**
Reg→FTD %	33.1%	37.8%	+14.2%	0.003	[+5.1%, +23.3%]
Avg 1st deposit	$48.20	$46.90	-2.7%	0.41	[-9.2%, +3.8%] — не значимо
Time-to-deposit	4.2 мин	2.8 мин	-33%	<0.001	[-42%, -24%]
Payment failure rate	2.1%	2.3%	+0.2pp	0.68	guardrail OK (не пробита)

Сегментация

Сегмент	**Control**	**Treatment**	**Δ**
Mobile (iOS + Android)	28.5%	35.2%	+23.5%
Desktop	41.2%	42.8%	+3.9% (не значимо)
CIS	35.0%	40.1%	+14.6%
LatAm	29.8%	34.5%	+15.8%

Решение и learnings

> *TIP: Решение: раскатить на 100%. Primary metric выросла на +14.2% (p=0.003, значимо). Guardrail не пробита. Средний депозит не упал значимо (-2.7%, p=0.41).*

Learnings

- Эффект сильнее на mobile (+23.5%) чем на desktop (+3.9%) — на мобильных каждый шаг стоит дороже
- Время до депозита сократилось с 4.2 до 2.8 минут — меньше friction = меньше дропа
- Следующая гипотеза: добавить Apple Pay / Google Pay для ещё большего упрощения (AB-07, в бэклоге)
- Ожидаемый бизнес-эффект: +14.2% FTD при 820 регистраций/день = ~+38 FTD/день = ~+$2,280/день NGR (при avg LTV $60)

Серая зона: неоднозначные результаты

Не все тесты дают чёткий ответ «раскатить / закрыть». Вот четыре типичных ситуации и как с ними поступать.

p = 0.06 — «почти значимо» [серая зона]

Ситуация: тест AB-02 (рекомендации игр). Session duration: control 8.2 мин, treatment 9.1 мин. Δ = +11%, но p = 0.06.

Что НЕ делать: не говорить «почти значимо» — в статистике нет «почти». p = 0.06 означает: недостаточно данных для вывода.

Что делать:

- Продлить тест на 3-5 дней — возможно, не хватило sample size
- Посмотреть CI: если 95% CI = [-0.5%, +22.5%], нижняя граница пересекает ноль — неопределённость
- Проверить сегменты: может быть значимый эффект на mobile но не на desktop
- Решение: если бизнес-стоимость внедрения низкая — можно раскатить с мониторингом. Если высокая — продлить или переделать тест

Значимый но крошечный эффект (+0.3%) [серая зона]

Ситуация: тест изменения цвета кнопки «Депозит». Reg→FTD: control 33.0%, treatment 33.3%. Δ = +0.3%, p = 0.04 (значимо при N = 50,000).

Проблема: статистическая значимость ≠ практическая значимость. При большом N можно найти значимость у любого мизерного эффекта.

Что делать:

- Считать ROI: +0.3% от 820 reg/день = +2.5 FTD/день = +$150/день. Если разработка заняла 2 дня (= $1,000 стоимость) — окупится за неделю. Может быть ок.
- Но: если внедрение сложное (рефакторинг, долгая поддержка) — не стоит. Фокусируйтесь на тестах с MDE > 5%.

Primary вырос, guardrail упал [опасность]

Ситуация: тест агрессивного welcome бонуса ($50 freebet вместо $20). Reg→FTD: +22% (p < 0.001). Но Retention D7: -8% (p = 0.02). Bonus cost ratio: +12pp.

Проблема: привлекли больше FTD, но это бонус-хантеры — депонируют минимум, проигрывают freebet, уходят. Конверсия выросла, но quality трафика упал.

Что делать:

- Не раскатывать. Guardrail пробита не просто так — она защищает от exactly this.
- Посчитать LTV 30d по группам: если LTV treatment < LTV control — однозначно закрываем
- Итерировать: промежуточный вариант ($30 freebet) или добавить условие (freebet только после депозита $20+)

Противоречивые сегменты [серая зона]

Ситуация: тест нового дизайна лобби казино. GGR per session: mobile +15% (p = 0.01), desktop -5% (p = 0.08). Общий эффект: +6% (p = 0.04).

Варианты:

- Раскатить только на mobile? Можно, если технически просто (responsive) и нет каннибализации. Но усложняет кодовую базу.
- Копать глубже: почему desktop хуже? Может быть, layout сломался на определённых разрешениях. Проверить: 1920px vs 1366px vs 1280px.
- Решение в данном случае: раскатить на mobile (70% трафика), починить desktop-баги, перетестировать desktop отдельно.

Anti-patterns: как НЕ надо

«Давайте просто попробуем» [anti-pattern]

Что происходит: PM говорит: «Давайте поменяем порядок игр в лобби и посмотрим что будет». Нет гипотезы, нет метрики, нет sample size. Через неделю: «вроде стало лучше» — или «вроде не изменилось».

Почему плохо: без заранее определённой метрики и MDE невозможно отличить шум от сигнала. «Вроде лучше» — это не результат, это confirmation bias.

Как правильно: сформулировать гипотезу: «Если переместить top-10 игр по GGR в начало лобби, то GGR per session вырастет на 8%, потому что игроки быстрее находят популярные игры». Рассчитать sample size. Запустить по чеклисту.

Остановили через 2 дня: «уже видно» [anti-pattern]

Что происходит: тест запущен в понедельник. Во вторник: treatment +25%! CEO: «Отлично, раскатываем!» К пятнице: эффект упал до +3% (не значимо).

Почему плохо: ранние результаты — шум. Первые дни привлекают novelty seekers. Выходные отличаются от будней. Без полного недельного цикла нельзя делать выводы.

Как правильно: no-peek commitment. Минимум 7 дней. Для sports-ставок — 14 дней (матчи по выходным). Единственное исключение: guardrail пробита → останавливаем.

5 вариантов без коррекции [anti-pattern]

Что происходит: дизайнер сделал 5 вариантов welcome-баннера. «Давайте протестируем все сразу!» Запускают A/B/C/D/E тест. Вариант D «побеждает» с p = 0.04.

Почему плохо: при 5 вариантах и $\alpha = 0.05$ вероятность хотя бы одного ложно-положительного $= 1 - (0.95)^4 = 18.5\%$. Нужна коррекция Бонферрони: $\alpha = 0.05/4 = 0.0125$ для каждого

сравнения. При этом пороге вариант D уже не значим.

Как правильно: максимум 2-3 варианта. Если нужно больше — сначала отсеять худшие качественно (UX-ревью), потом тестировать 2 финалиста. Или использовать sequential testing с коррекцией.

A/B тест на VIP (30 человек) [anti-pattern]

Что происходит: VIP-менеджер хочет протестировать новую бонусную программу для whale-игроков. В VIP-сегменте 30 человек. Тест запущен на 15 vs 15.

Почему плохо: при N = 15 per group и baseline conversion 50% минимально детектируемый эффект = +35%. То есть тест покажет значимость только если конверсия вырастет с 50% до 67.5% — нереалистично. Любой результат будет шумом.

Как правильно: для малых сегментов A/B тестирование не работает. Используйте вместо этого: (1) пре/пост анализ с учётом сезонности, (2) qualitative research (интервью с VIP), (3) пилот → замер → решение (без статистической значимости, но с бизнес-логикой).

14. Management Practices

Как организована работа data-команды: спринты, встречи, OKR, бэклог и база знаний.

Структура спринта

2-недельные спринты. Баланс: 70% roadmap-задачи / 30% буфер на ad-hoc запросы от бизнеса.

- **Понедельник W1 — Planning (1ч)**
  Лиды представляют задачи из бэклога. Оценка в story points. Коммитмент команды. Буфер 30% не планируется — резерв на ad-hoc.
- **Ежедневно — Standup (15 мин)**
  Async в Slack (текстовый формат) или короткий call. Три вопроса: что сделал, что буду делать, есть ли блокеры. Не для отчётности — для синхронизации.
- **Среда W1 — Mid-sprint check**
  Лид проверяет прогресс: что в трекере, есть ли риски по дедлайну. Если ad-hoc забрал больше 30% — пересогласовать scope.
- **Пятница W2 — Review (1ч)**
  Демо результатов: новые дашборды, модели, пайплайны. Стейкхолдеры приглашены. Фидбек фиксируется в бэклоге.
- **Пятница W2 — Retro (30 мин)**
  Что пошло хорошо / что пошло не так / что улучшить. Action items с владельцем. Ротация фасилитатора между стримами.

Регулярные встречи

Встреча	Участники	Частота	Длительность	Цель
1-on-1 Director ↔ Lead	Director + каждый Lead	Еженедельно	30 мин	Люди, процессы, стратегия
Director ↔ C-level	Director + CEO/CFO/CMO	Раз в 2 недели	45 мин	Статус, приоритеты, ресурсы
All-hands Data	Вся data-команда (20 чел)	Ежемесячно	1ч	Результаты, roadmap, признание
Governance Council	Director + Owners + Leads	Ежеквартально	1.5ч	DQ, определения, политики
Cross-functional sync	Lead Analyst + PM/Marketing/Finance	Еженедельно	30 мин	Приоритеты ad-hoc, статус задач

1-on-1 с лидом

30 минут еженедельно. Агенду ставит лид (не директор). Три блока:

People

Как дела в команде? Кто перегружен, кто недогружен? Есть ли конфликты? Кого пора повышать? Настроение и мотивация.

Process

Что мешает работать? Блокеры, зависимости от других команд, технический долг. Что улучшить в процессах?

Strategy

Куда движемся? Правильные ли приоритеты? Что важного мы не делаем? Идеи для следующего квартала.

> *INFO: Правило: если 1-on-1 превращается в статус-апдейт по задачам — что-то идёт не так. Для статуса есть standup и Jira. 1-on-1 — про людей и стратегию.*

OKR Framework

Квартальные OKR. Устанавливаются Director + Leads, синхронизируются с компанейскими OKR.

Пример: Q2 2026

Objective: Обеспечить data-driven принятие решений во всех бизнес-функциях

Key Result	Target	Текущий	Owner
100% critical marts покрыты SLA с мониторингом	100%	100%	Lead DE
80% ad-hoc запросов решаются через self-service (Metabase)	80%	62%	Lead BI
LTV-модель в production с MAPE < 20%	MAPE <20%	18.7%	Lead DS
3 data literacy воркшопа проведены	3	1	Data Literacy Spec.

Управление бэклогом

Как приходят запросы

- Jira-форма: стейкхолдер заполняет: что нужно, зачем, к когда, кто потребитель. Автоматически попадает в бэклог.
- Slack #data-requests: для срочных/простых вопросов. Бот напоминает оформить тикет если вопрос не закрыт за 24ч.
- Cross-functional sync: еженедельно PM/Marketing/Finance приносят приоритеты.

Приоритизация (RICE)

Фактор	Описание	Шкала
Reach	Сколько людей/процессов затронет за квартал	Кол-во пользователей
Impact	Насколько сильно повлияет на метрику	3 / 2 / 1 / 0.5 / 0.25
Confidence	Уверенность в оценке	100% / 80% / 50%
Effort	Человеко-недели	Число

RICE Score = (Reach × Impact × Confidence) / Effort

Коммуникация статуса

- Slack-бот: автоматическое обновление при смене статуса тикета (in progress, done, blocked)
- Weekly digest: каждую пятницу в #data-updates — что закрыли, что в работе, что заблокировано

Пример: три запроса, ресурсы на один

Реальная ситуация: три стейкхолдера одновременно просят срочную задачу. В спринте осталось 12 человеко-дней свободной ёмкости. Каждая задача — ~10 дней.

Запрос	От кого	RICE	Effort	Решение
Churn-модель в production	CPO	680	10 дней	Sprint 12 (приоритет)
Новый дашборд P&L	CFO	450	8 дней	Sprint 13
Аудит GA4 тегов	CMO	120	5 дней	Бэклог, Q3

Почему churn-модель важнее P&L дашборда?

RICE помог расставить приоритеты, но CFO недоволен: «мне нужен P&L-отчёт к совету директоров».

Эскалация: Director выносит на bi-weekly sync с C-level. Аргументация через бизнес-impact:

- Churn-модель: при текущем churn 8%/мес мы теряем ~1,400 игроков/мес × avg LTV $180 = $252K/мес revenue at risk . Модель снижает churn на 18% (по пилоту) = $45K/мес сохранённого revenue.
- P&L дашборд: CFO и так получает данные в Excel от Financial Analyst. Дашборд — удобство, не блокер. Ценность = экономия ~4 часов/неделю работы аналитика.

Решение C-level: churn-модель идёт в Sprint 12. P&L дашборд — в Sprint 13. CFO получает промежуточное решение: улучшенный Excel-шаблон на время ожидания.

Capacity Planning

Как считать реальную ёмкость команды на спринт. Частая ошибка — планировать от «20 человек × 10 дней = 200 дней». Реальность другая.

Фактор	Расчёт	Человеко-дней
Общая ёмкость	20 чел × 10 рабочих дней	200
Ad-hoc буфер (30%)	200 × 0.30	-60
= Доступно для roadmap		140
Отпуска, больничные (~10%)	140 × 0.10	-14
= После отпусков		126

Фактор	Расчёт	Человеко-дней
On-call, встречи, код-ревью (~15%)	126 × 0.15	-19
= Реально на фичи		~107

> *WARNING: Правило: из 200 человеко-дней в спринте реально доступны ~107 на roadmap-задачи. Планируйте от этого числа, не от 200. Если планировать от 200 — каждый спринт будет «провален», команда демотивирована, стейкхолдеры разочарованы.*

Распределение по стримам (Sprint 12)

Стрим	Люди	Ёмкость (грубо)	Roadmap задачи
Data Engineering	5	~27 дней	Churn model pipeline + Feature Store интеграция
Analytics	8	~43 дня	3 ad-hoc, cohort deep dive, weekly reports
Data Science	4	~21 день	Churn model v2 training + A/B analysis
BI Engineering	3	~16 дней	Self-service воркшоп + шаблон P&L (prep)

Delegation Framework

Что директор делает сам, что полностью делегирует лидам, что решается совместно. Чёткие границы снижают bottleneck на директоре и дают лидам автономию.

Зона принятия решений	Директор	Лид	Совместно
Найм — финальное решение			
Найм — интервью и отбор			
Приоритизация внутри стрима			
Приоритизация между стримами			
OKR — цели (Objectives)			
OKR — ключевые результаты (KR)			
Бюджет			
Архитектурные решения			
Инцидент P1			
Инцидент P2/P3			
Повышения и пересмотр грейдов			
Увольнения			
Технический долг — приоритизация			
Внешние интеграции и vendor selection			

> *INFO: Принцип: директор принимает решения, которые затрагивают несколько стримов или бюджет. Лид принимает решения внутри своего стрима. «Совместно» = лид предлагает, директор утверждает (или наоборот). Цель: максимум автономии лидам при сохранении согласованности.*

База знаний

Wiki в Confluence. Структура по разделам. Правило: если объяснил в Slack — напиши в wiki.

Раздел	Содержимое	Owner
Architecture	Стек, ERD, dbt lineage, ADR (Architecture Decision Records)	Lead DE
Metrics	Data Dictionary, формулы, SQL-примеры	Lead Analyst
Processes	CI/CD, on-call, incident response, A/B testing	Lead DE + Lead DS
Runbooks	Типичные инциденты и как их чинить	DE team
Onboarding	Чеклист новичка, доступы, первые задачи	Director

> *TIP: Правило двух раз: если один и тот же вопрос задали в Slack дважды — ответ должен появиться в wiki. Иначе знания остаются в головах и теряются при увольнении.*

15. Onboarding Guide

Путь нового сотрудника data-команды: от получения доступов до самостоятельных задач. Buddy, data tour, первый PR — за 30 дней.

Этот гайд покрывает общий onboarding для всех ролей в data-команде. Специфика по стримам (DE, Analytics, DS, BI) — через buddy и лида.

День 1–3: Доступы и знакомство

Первые дни — административный setup и знакомство с командой. Цель: к концу дня 3 у тебя есть все доступы и понимание, кто чем занимается.

Доступы (Day 1)

Система	Что получаешь	Кто
ClickHouse	Read-only аккаунт к DWH (staging + prod)	Platform DE
Metabase	Viewer role, доступ ко всем дашбордам	BI Lead
GitHub	Contributor в data-dbt и data-pipelines repos	DE Lead
Airflow	Read-only UI для мониторинга DAGs	Platform DE
Slack	Channels: #data-team, #data-alerts, #data-questions, #data-wins	HR / Lead
Jira / Linear	Доступ к Data project board	Lead
Confluence / Wiki	Data Knowledge Base space	Lead
DataHub	Viewer role — каталог данных	Platform DE

> *WARNING: PII-данные (player email, phone, документы) доступны только после прохождения compliance-тренинга (обычно неделя 2). До этого — masked views.*

Buddy (Day 1)

Каждому новичку назначается buddy — опытный сотрудник из того же стрима (или смежного). Buddy — не руководитель, а навигатор.

Что делает buddy	Чего buddy НЕ делает
Отвечает на «глупые» вопросы без осуждения	Не оценивает performance
Помогает разобраться в контексте задач	Не назначает задачи
Code review первых PR	Не заменяет лида
Обед/кофе в первую неделю	Не отвечает за retention

Buddy назначается лидом стрима до выхода нового сотрудника. Длительность: 1 месяц, далее по желанию.

Знакомство с командой (Day 1–2)

- Day 1, 11:00 — Welcome-встреча с лидом стрима (30 мин). Обзор команды, приоритетов, ожиданий.
- Day 1, 14:00 — Знакомство с buddy. Совместный обед или кофе.

- Day 2, 10:00 — Встреча с Director of Data (15 мин). Миссия data-функции, big picture.
- Day 2, 11:00 — Круг знакомств: 15-минутные 1-on-1 с каждым лидом стрима.
- Day 2–3 — Присутствие на ближайшем daily standup и sprint review как наблюдатель.

Обязательное чтение (Day 2–3)

- Metrics Dictionary — ключевые метрики бизнеса (NGR, GGR, LTV, Churn)
- Event Taxonomy — naming convention, как устроены события
- Data Governance — ownership, доступы, DQ framework
- Wiki: Data Dictionary — стандартные определения терминов
- Wiki: Team Norms — code style, PR process, communication rules

> *TIP: Не пытайся запомнить всё за 2 дня. Цель чтения — сформировать mental map: «знаю, что это существует и где найти». Детали придут с практикой.*

Неделя 1: Data Tour

Главное событие первой недели — «Data Tour»: ты проходишь путь данных от события до дашборда. Это даёт целостное понимание архитектуры.

Data Tour: от события до дашборда

Вместе с buddy проходишь end-to-end путь конкретной метрики (обычно NGR):

- **1. Источник**
  Betting Engine генерирует событие player_bet_placed . Смотрим формат в Event Taxonomy .
- **2. Ingestion**
  Событие попадает в Kafka → Airbyte загружает в ClickHouse raw layer. Смотрим Airflow UI — DAG ingest_kafka_bets .
- **3. Transformation**
  dbt модели: stg_betting__bets → int_bets_enriched → mart_daily_kpi . Открываем код в GitHub, запускаем dbt run --select mart_daily_kpi на staging.
- **4. Quality**
  dbt tests на mart_daily_kpi: uniqueness, not_null, referential integrity. Смотрим результаты в Airflow.
- **5. Dashboard**
  Открываем Metabase → CEO Daily Pulse → видим NGR, который мы только что проследили от события до цифры. Подробнее в Dashboards .

Полная схема lineage: Data Lineage .

Архитектурный обзор

С buddy или лидом DE проходишь Data Architecture :

- 9 слоёв стека: что каждый делает, какой инструмент, почему выбран
- Как слои связаны между собой
- Где логи, мониторинг, алерты

После обзора — самостоятельно пройдись по Data Model : ERD, таблицы, поля.

Первый SELECT

К концу недели 1 ты должен самостоятельно написать запрос к DWH. Задание от buddy:

SQL

```
-- Задание: посчитай основные метрики за последние 7 дней
SELECT
    dt,
    active_players,
    turnover,
    ggr,
    ngr
FROM mart_daily_kpi
WHERE dt >= today() - 7
ORDER BY dt DESC;
```

Цель: убедиться, что доступы работают и ты понимаешь структуру mart-таблиц. Запусти запрос в DBeaver / DataGrip / ClickHouse client и посмотри, какие колонки есть в mart_daily_kpi.

Неделя 2: Первые задачи

Переходим от наблюдения к действию. Все задачи — под присмотром buddy с обязательным code review.

Первый ad-hoc (под buddy)

Buddy выбирает простой ad-hoc запрос из бэклога (обычно помеченный good-first-issue). Примеры:

- «Покажи top-10 игр по GGR за последний месяц в LatAm»
- «Посчитай retention D7 для когорты FTD прошлой недели»
- «Сравни конверсию Reg→FTD по платформам (web vs mobile)»

Результат оформляется в виде Metabase question или SQL + комментарий в Jira-тикете. Buddy ревьюит логику и SQL.

Первый dbt PR

Типовая первая задача в dbt — добавить тест или исправить модель. Buddy подбирает задачу:

Пример: добавить тест на уникальность

YAML

```yaml
# models/staging/betting/_betting__models.yml
models:
  - name: stg_betting__bets
    columns:
      - name: bet_id
        tests:
          - unique
          - not_null
      - name: player_id
        tests:
          - not_null
          - relationships:
              to: ref('stg_core__players')
              field: player_id
```

Процесс:

- Fork / branch: feat/add-bets-tests
- Локальный dbt test --select stg_betting__bets
- PR → code review от buddy → merge

Подробнее о процессе: DataOps (CI/CD for data).

Compliance-тренинг

В течение недели 2 проходишь обязательный compliance-тренинг:

- Data Privacy: GDPR basics, что считается PII, как работает маскирование
- Responsible Gambling: self-exclusion, лимиты, обязанности оператора
- Information Security: пароли, VPN, обращение с данными

После прохождения — получаешь доступ к PII-данным (если роль требует). Доступ выдаёт Head of Compliance.

Месяц 1: Самостоятельная работа

К концу первого месяца ты должен работать самостоятельно (buddy доступен, но инициатива — твоя).

Ожидания по ролям

Роль	К концу месяца 1
Data Engineer	Самостоятельно дебажит failed DAGs, написал 1 новую stg-модель, участвует в on-call rotation (shadow)
Analyst	Закрыл 2-3 ad-hoc задачи, создал 1 Metabase question, участвовал в sprint planning
Data Scientist	Разобрался в Feature Store, воспроизвёл baseline модель (LTV или Churn) в Jupyter, начал EDA для новой задачи
BI Developer	Создал 1 дашборд по шаблону, разобрался в semantic layer, провёл 1 сессию data literacy

Участие в процессах

- Sprint planning — активное участие: берёшь задачи, оцениваешь сложность
- Sprint review — демонстрируешь свою работу команде
- Retro — делишься свежим взглядом (newbie perspective ценна!)
- Daily standup — полноценный участник: что сделал, что планирую, блокеры

Подробнее о процессах: Management Practices .

Feedback-сессия с лидом

В конце месяца 1 — обязательная 1-on-1 с лидом стрима (45 мин):

- Как прошёл onboarding: что было понятно, что нет, что можно улучшить
- Прогресс: обзор выполненных задач, quality code review, feedback от buddy
- Ожидания на месяц 2-3: конкретные цели и зоны роста
- Обратная связь от новичка: что удивило, что можно улучшить в процессах

> *TIP: Feedback новичка — один из лучших источников улучшений. Свежий взгляд замечает то, к чему команда привыкла. Всё, что озвучено — фиксируется и разбирается.*

Onboarding Checklist

Интерактивный чеклист — отмечай выполненные пункты. Прогресс сохраняется в браузере.

День 1–3

- [ ] Получены все доступы (ClickHouse, Metabase, GitHub, Airflow, Slack, Jira)
- [ ] Назначен buddy, состоялась первая встреча
- [ ] Встреча с Director of Data
- [ ] Знакомство с лидами стримов
- [ ] Прочитаны: Metrics Dictionary, Event Taxonomy, Data Governance

Неделя 1

- [ ] Data Tour пройден (от события до дашборда)
- [ ] Архитектурный обзор с buddy/лидом DE
- [ ] Первый SELECT к DWH выполнен
- [ ] Присутствие на daily standup

Неделя 2

- [ ] Первый ad-hoc запрос (под buddy)
- [ ] Первый dbt PR (тест или fix)
- [ ] Compliance-тренинг пройден

Месяц 1

- [ ] Самостоятельная задача без buddy-ревью
- [ ] Участие в sprint planning + review
- [ ] Участие в retro (поделился свежим взглядом)

Feedback-сессия с лидом стрима

.

.

.

.

.

16. FinOps

Сколько стоит data-функция Fantasy iGaming и как оптимизировать затраты. Инфраструктура, SaaS, люди — полная раскладка.

Все цифры — реалистичные оценки для компании масштаба Fantasy iGaming (~500K MAU, ~$5M NGR/мес). Фактические затраты зависят от региона, провайдера и условий контракта.

Структура затрат

Общий бюджет data-функции: ~$165K/мес (~$2M/год). Это ~3.3% от NGR — в рамках индустриального бенчмарка (2-5%).

Инфраструктура — ~$18K/мес

Компонент	Конфигурация	$/мес	Заметки
ClickHouse cluster	3 ноды × 32 vCPU, 128GB RAM, 2TB NVMe + 3 ноды cold storage	$8,500	Self-hosted на Hetzner/OVH. Managed (ClickHouse Cloud) был бы ~$15K
Kafka cluster	3 брокера, ~50K msg/sec peak	$2,400	Self-hosted. Confluent Cloud ~$5K+
Airflow	Kubernetes, 2 workers × 8 vCPU, 16GB RAM	$1,800	Self-hosted. Astronomer ~$4K+
GCS (Data Lake)	~15TB raw + 5TB Parquet archives	$400	Cold storage tier. Negligible egress (internal only)
Kubernetes (GKE)	Node pool для ML workloads + serving	$3,200	GPU-ноды для обучения моделей (on-demand)
Networking / Monitoring	VPN, Grafana Cloud, PagerDuty	$1,200	Grafana self-hosted экономит ~$500

> *TIP: Self-hosted стек экономит ~40% vs managed, но требует 1 Platform DE full-time. Trade-off окупается при нашем масштабе ($60K+ экономии/год > стоимость 1 FTE времени на ops).*

SaaS & Лицензии — ~$7K/мес

Инструмент	Тип	$/мес	Альтернатива
Airbyte	Self-hosted (open-source)	$0*	Fivetran (~$3K/мес при нашем объёме коннекторов)
dbt Core	Open-source	$0*	dbt Cloud ($5K+/мес)
Metabase	Self-hosted (open-source)	$0*	Tableau ($2K+/мес), Looker ($5K+/мес)
MLflow	Self-hosted (open-source)	$0*	Weights & Biases ($1.5K/мес)
DataHub	Self-hosted (open-source)	$0*	Atlan ($3K+/мес), Alation ($5K+/мес)
Census	SaaS	$1,500	Hightouch (~$1.2K), self-built (DE time)
Great Expectations	Open-source	$0*	Monte Carlo ($3K+/мес)
Feast	Open-source	$0*	Tecton ($2K+/мес)
Slack, Jira, Confluence	SaaS (company-wide)	$2,800	Пропорция на data team (20 из 300 чел.)
IDE лицензии	DataGrip, PyCharm (JetBrains)	$800	VS Code (free)
Cloud services	Looker Studio, GA4 (marketing)	$500	Free tier covers most

Инструмент	Тип	$/мес	Альтернатива
Adjust	SaaS (пропорция data)	$1,400	AppsFlyer (~$1.5K)

* Self-hosted = $0 лицензия, но включено в стоимость инфраструктуры и Platform DE time.

> *INFO: Open-source first strategy экономит ~$20K/мес vs full-SaaS стек. Но требует DE-компетенции в ops. Главный риск: bus factor на Platform DE.*

Люди — ~$140K/мес

Крупнейшая статья расходов — 85% бюджета. 20 FTE в 4 стримах.

Роль	Кол-во	Avg $/мес (gross)	Subtotal
Director of Data	1	$12,000	$12,000
Lead (DE, Analytics, DS, BI)	4	$9,000	$36,000
Senior DE / Analyst / DS	5	$7,500	$37,500
Middle DE / Analyst / DS / BI	7	$5,500	$38,500
Junior Analyst / BI	3	$3,500	$10,500
Total people cost	~$134,500		
+ Benefits, taxes (~15%)	~$5,500 (в рамках CIS рынка)		

> *INFO: Зарплаты — рыночные для CIS (primary market). Для Europe / LatAm офисов множитель 1.3-2x. Подробнее о ролях: Org Structure .*

Cost Summary

Summary

Категория	$/мес	% от бюджета	% от NGR
Люди	$140,000	85%	2.8%
Инфраструктура	$18,000	11%	0.36%
SaaS & Лицензии	$7,000	4%	0.14%
Total	$165,000	100%	3.3%

Оптимизация затрат

Экономия без потери качества — постоянный процесс. Основные рычаги:

ClickHouse: партиционирование и TTL

Крупнейшая статья инфраструктуры. Два главных рычага:

Партиционирование

Все fact-таблицы партиционированы по месяцам. Запросы за последний месяц не сканируют исторические данные — экономия IO и CPU.

SQL

```
CREATE TABLE fct_bets (
    bet_id String,
    player_id String,
    bet_amount Decimal(18,2),
    placed_at DateTime
) ENGINE = MergeTree()
PARTITION BY toYYYYMM(placed_at)
ORDER BY (player_id, placed_at);
```

TTL (Time-to-Live)

Автоматическое перемещение старых данных на дешёвое хранилище:

SQL

```
ALTER TABLE fct_bets
    MODIFY TTL
        placed_at + INTERVAL 3 MONTH TO VOLUME 'hot',     -- NVMe SSD
        placed_at + INTERVAL 12 MONTH TO VOLUME 'cold',   -- HDD
        placed_at + INTERVAL 5 YEAR DELETE;                -- Archive to GCS first
```

Экономия: ~30% стоимости хранения (HDD в 5-8x дешевле NVMe).

Materialized Views

Часто используемые агрегаты вычисляются один раз при вставке, а не при каждом запросе:

SQL

```
CREATE MATERIALIZED VIEW mv_daily_ggr
ENGINE = SummingMergeTree()
PARTITION BY toYYYYMM(date)
ORDER BY (date, geo, product)
AS SELECT
    toDate(placed_at) AS date,
    geo,
    product,
    sum(bet_amount) AS total_bets,
    sum(payout_amount) AS total_payouts,
    sum(bet_amount) - sum(payout_amount) AS ggr
FROM fct_bets
GROUP BY date, geo, product;
```

Экономия: дашборды грузятся в 10-50x быстрее, CPU cluster использование -40% в пиковые часы.

Query Optimization

Top-3 частых проблем и их решения:

Проблема	Симптом	Решение	Экономия
SELECT * на больших таблицах	Timeout, high memory	Выбирать только нужные колонки	~60% IO

Проблема	Симптом	Решение	Экономия
JOIN без предварительной фильтрации	Slow query, OOM	Фильтр по дате ДО join	~80% CPU
Отсутствие LIMIT на ad-hoc	Огромный result set	Default LIMIT 10000, query governor	Prevents OOM

> *TIP: Раз в квартал — «Query Review Day»: анализируем system.query_log, находим top-20 самых тяжёлых запросов, оптимизируем или кешируем.*

Reserved Instances & Spot

Для стабильных workloads — reserved instances (commitment 1 год):

Workload	Тип	Экономия vs on-demand
ClickHouse nodes (24/7)	Reserved 1yr	~30-40%
Airflow workers (24/7)	Reserved 1yr	~30-40%
ML training jobs (batch)	Spot / Preemptible	~60-70%
dbt runs (batch, 2h/day)	On-demand (autoscale)	Pay only when running

Общая экономия от reserved + spot: ~$3K/мес ($36K/год).

Бюджетное планирование

Годовой бюджет data-функции утверждается CFO в Q4 предыдущего года. Структура:

Годовой бюджет 2026

Статья	$/год	% от total	Тренд vs 2025
Payroll (20 FTE)	$1,680,000	85%	+12% (3 new hires + salary review)
Infrastructure	$216,000	11%	+8% (data growth ~2x/year)
SaaS & Licenses	$84,000	4%	-5% (migrated 2 tools to self-hosted)
Training & Conferences	$30,000	—	$1,500/person/year
Contingency	$15,000	—	Emergency: unexpected infra spike, urgent hire
Total	$2,025,000		

Как защитить бюджет перед CFO

CFO не разбирается в ClickHouse и dbt. Говори на языке бизнеса:

Фреймворк ROI

- Revenue impact: «LTV-модель увеличила retention целевого сегмента на 4% → +$240K NGR/год»
- Cost avoidance: «Self-hosted ClickHouse vs BigQuery экономит $180K/год при нашем объёме»
- Efficiency: «Self-service BI сократил ad-hoc запросы на 60% → высвободили 1.5 FTE аналитиков на research»
- Risk mitigation: «DQ framework предотвращает инциденты типа wrong CEO report → репутационный и операционный риск»

Метрики для CFO

Метрика	Значение	Бенчмарк
Data cost / NGR	3.3%	2-5% (industry)
Data cost / employee	$8,250/мес	Varies by region
Infrastructure / total data cost	11%	10-25% (depends on self-hosted vs managed)
Self-service adoption	80% ad-hoc	Reduces analyst bottleneck

> *TIP: Лучший аргумент — конкретный кейс: «В Q2 модель churn prediction позволила удержать сегмент с LTV $500+ — estimated impact $180K. Стоимость DS-стрима за квартал — $120K. ROI > 1.5x.»*

Квартальный cost review

Раз в квартал Director of Data проводит cost review:

- Actual vs Budget: отклонения > 10% — разбор причин
- Cost per query: тренд средней стоимости запроса в ClickHouse
- Unused resources: idle instances, unused SaaS seats, stale pipelines
- Growth forecast: проекция затрат на следующий квартал с учётом роста данных

Результат — memo для CFO с рекомендациями (оптимизация, capacity planning, hiring needs).

.

.

.

17. Annual Roadmap

Годовой план data-функции Fantasy iGaming на 2026 год. 4 квартала: от стабилизации основ до масштабирования и real-time аналитики.

Roadmap — живой документ. Пересматривается каждый квартал на Governance Council. Приоритеты могут сдвигаться в зависимости от бизнес-потребностей.

Timeline

Январь — Март

- DQ framework live
- SLA defined & tracked
- Data Dictionary v1
- Governance roles assigned
- On-call rotation launched

Апрель — Июнь

- Semantic layer (Metabase)
- Metabase rollout (all teams)
- Data literacy workshops (3 sessions)
- 80% ad-hoc via self-service
- Dashboard templates library

Июль — Сентябрь

- Recommendation engine MVP
- Fraud model v2 (enhanced features)
- Churn model optimization (precision +10%)
- Feature Store live
- A/B testing framework operational

Октябрь — Декабрь

- Real-time analytics (streaming marts)
- Reverse ETL → CRM (Census)
- Fraud model v2 → real-time deployment
- Platform cost optimization (-20%)
- Data mesh evaluation

Q1 — Stabilize

Фундамент. Без стабильной базы всё остальное — карточный домик. Фокус на качество данных, процессы и ownership.

DQ Framework

Deliverable	Owner	Status
dbt tests на все critical marts (>50 тестов)	Analytics Engineer	done
Great Expectations suites для cross-table validation	DE Lead	done
DQ dashboard в Grafana (freshness, completeness, accuracy)	Platform DE	done
Alerting: Slack #data-alerts + PagerDuty для P1	Platform DE	done

Подробнее: Data Governance (DQ framework).

SLA & On-call

- SLA matrix — определены targets для всех пар provider → consumer. SLA
- On-call rotation — DE ротация по неделям, runbook для типовых инцидентов. DataOps
- Incident process — severity levels, response protocol, post-mortem template. Incident Response

Governance & Dictionary

- Data Owners назначены по 4 доменам (Product, Finance, Marketing, Compliance)
- Data Dictionary v1 — 50+ стандартных определений утверждены на Governance Council
- DataHub — каталог данных с lineage, описаниями, ownership
- RBAC — матрица доступов настроена, PII masked для non-compliance ролей

Подробнее: Data Governance .

Q2 — Self-service

Масштабирование через self-service. Цель: бизнес-пользователи сами отвечают на 80% вопросов, аналитики фокусируются на research.

Semantic Layer & Metabase Rollout

Deliverable	Owner	Status
Semantic layer: стандартные metrics и dimensions в Metabase	BI Lead	in progress
Dashboard templates: CEO, Marketing, Product, Finance	BI Developer	in progress
Metabase training для Product и Marketing teams	Data Literacy Specialist	in progress
Self-service metrics: 80% ad-hoc через Metabase	BI Lead	planned

Data Literacy Program

3 воркшопа для бизнес-пользователей:

#	Тема	Аудитория	Формат
1	Metabase basics: фильтры, questions, dashboards	All business users	Workshop 2h + practice
2	Metrics that matter: NGR, LTV, Retention — что значат и как читать	Product + Marketing	Lecture 1.5h + Q&A
3	SQL basics: SELECT, WHERE, GROUP BY для ad-hoc	Power users (optional)	Workshop 3h + homework

Подробнее: Dashboards , Metrics Dictionary .

Q3 — ML to Prod

LTV и Churn модели уже в production (деплой в Q2). Q3 — оптимизация существующих моделей, новые use cases (recommendations, fraud v2), Feature Store и A/B testing framework.

Models in Production

Модель	Task	Target Metric	Timeline	Dependencies
Recommendation Engine	Персонализированные рекомендации игр	CTR +15% vs random	July — MVP	Feature Store, fct_bets, fct_sessions
Fraud Model v2	Enhanced features: device fingerprint, velocity	FPR < 2% (was 3.2%)	Aug — deployed	Feature Store, real-time pipeline
Churn Optimization	Precision +10% для high-LTV сегмента	Precision > 0.75	Aug — deployed	LTV model (segments), Feature Store
A/B Testing	Framework: sample size, analysis, reporting	3 tests/quarter	Sep — operational	Metrics Dictionary, Product buy-in

Model details: MLOps . A/B framework: A/B Testing .

Feature Store & MLOps

- Feast deployment — 30+ features (player behavior, deposit patterns, game preferences)
- MLflow registry — versioning, staging → production promotion
- Model monitoring — PSI drift detection, performance degradation alerts
- Retraining pipeline — monthly automated retraining with Airflow

Подробнее: MLOps (Feature Store, monitoring).

Q4 — Scale

Масштабирование: real-time, Reverse ETL, fraud v2, оптимизация затрат. Подготовка фундамента на 2027.

Real-time Analytics

Переход от batch (daily) к near-real-time для критичных метрик:

Метрика	Сейчас	Цель	Как
NGR	Daily (07:00)	15 min lag	Kafka → ClickHouse materialized view
Active Players	Daily	Real-time	Kafka Streams counter
Fraud Score	<100ms (already)	Maintain	Model v2 with more features
Deposit monitoring	Hourly	5 min	ClickHouse streaming insert

> *WARNING: Real-time ≠ всё real-time. Только метрики, где latency напрямую влияет на решения (fraud, live ops). Для финансовой отчётности daily batch остаётся gold standard.*

Reverse ETL & Closed Loop

Замыкаем цикл: данные → модель → действие → результат → данные.

- Churn → CRM: churn_score > 0.7 → CRM segment «At Risk» → персонализированный бонус

- LTV → Ad Platforms: LTV segments → Facebook/Google Ads → bid optimization
- Recommendations → Product: game recommendations → in-app placement → engagement uplift

Инструмент: Census (DWH → CRM, Ad platforms). Подробнее: Data Architecture (Reverse ETL).

Cost Optimization (-20%)

Цель Q4: снизить infrastructure cost на 20% ($3.6K/мес от $18K/мес infrastructure, не от total budget) при росте данных 2x:

- ClickHouse cold storage migration (TTL policies)
- Reserved instances для стабильных workloads
- ML training на spot instances
- Quarterly query review — оптимизация top-20 heavy queries
- Unused resource cleanup

Подробнее: FinOps .

Data Mesh Evaluation

Evaluation (не migration) — готовность к data mesh при дальнейшем масштабировании:

- Вопрос: при 50+ человек в data — нужна ли децентрализация?
- Оценить: domain ownership maturity, self-serve platform readiness, team autonomy
- Deliverable: Recommendation document для C-level (stay centralized / hybrid / start mesh transition)

> *TIP: Data mesh — не цель, а средство. При 20 людях централизованная модель работает отлично. Evaluation нужен, чтобы быть готовым к росту, а не чтобы модно выглядеть.*

Зависимости между кварталами

Deliverable	Зависит от	Блокирует
DQ Framework (Q1)	—	Self-service (Q2), ML models (Q3)
Data Dictionary (Q1)	—	Semantic layer (Q2), Metrics in models (Q3)
Semantic Layer (Q2)	Data Dictionary (Q1)	Self-service 80% (Q2)
Feature Store (Q3)	DQ Framework (Q1), mart tables	Recommendation engine (Q3), Fraud v2 (Q3)
Recommendation Engine (Q3)	Feature Store (Q3)	Reverse ETL → Product (Q4)
Fraud v2 (Q3)	Feature Store (Q3), real-time pipeline	Real-time analytics (Q4)
Real-time (Q4)	Stable batch pipelines (Q1-Q3)	—
Cost optimization (Q4)	Full platform deployed (Q1-Q3)	—

> *WARNING: Главный риск: Feature Store задержка → сдвигает Recommendation engine и Fraud v2 в Q3 → каскад на Reverse ETL Q4. Митигация: начать Feature Store в конце Q2.*

.

.

.

.

.

Приложение A: Glossary

Все термины проекта в одном месте. Краткое определение + ссылка на раздел, где термин раскрыт подробнее.

Термины отсортированы по алфавиту (A-Z). Кликните на букву, чтобы раскрыть список.

A/B Testing

Метод контролируемого эксперимента: аудитория делится на группы (control / treatment), одной показывают изменение, другой — нет. Сравнивается влияние на целевую метрику. A/B Testing

Acquisition

Привлечение новых пользователей. В iGaming — путь от первого визита до первого депозита (FTD). Измеряется через CPA, CAC, конверсионную воронку. Metrics Dictionary

Active Player

Игрок, совершивший хотя бы одну ставку за последние 30 дней. Основа для расчёта DAU/WAU/MAU. Определение зафиксировано в Data Dictionary. Data Governance

Adjust

Mobile measurement partner (MMP) — SDK для атрибуции мобильных установок, in-app событий и маркетинговых кампаний. Альтернатива: AppsFlyer. Data Architecture

Airbyte

Open-source платформа для ingestion данных. 300+ коннекторов, self-hosted. Загружает данные из источников в DWH. Альтернатива: Fivetran (managed, дороже). Data Architecture

Airflow (Apache Airflow)

Оркестратор пайплайнов данных. Управляет DAGs — направленными ациклическими графами задач. Обеспечивает расписание, retry, мониторинг, алерты. Data Architecture

Analytics Engineer

Роль на стыке DE и Analytics. Отвечает за dbt-модели, data quality, семантический слой. Работает с данными после ingestion — до BI. Org Structure

Attribution

Определение источника привлечения пользователя (какая кампания, канал, креатив привёл игрока). Ключевое для маркетинговой аналитики и расчёта ROAS. Metrics Dictionary

AUC (Area Under Curve)

Метрика качества бинарного классификатора. Площадь под ROC-кривой. Чем ближе к 1.0, тем лучше модель отличает классы. В проекте: Churn AUC 0.84, Fraud AUC 0.91. MLOps

Batch Processing

Обработка данных порциями по расписанию (например, daily). Противоположность real-time / streaming. Большинство пайплайнов Fantasy iGaming — batch (ежедневный dbt run). DataOps

BI (Business Intelligence)

Инструменты и практики визуализации данных для принятия бизнес-решений. В проекте: Metabase (primary), Looker Studio (marketing). Data Architecture

BigQuery

Serverless columnar DWH от Google Cloud. Альтернатива ClickHouse. Плюс: не нужен ops. Минус: дороже при масштабе без правильного partitioning. Data Architecture

Bonus Cost

Затраты на бонусы игрокам (welcome bonus, cashback, freebet, freespin). Вычитается из GGR при расчёте NGR. Типовой benchmark: 10-15% от GGR. Metrics Dictionary

Bonus Cost Ratio

Отношение bonus cost к GGR (в %). Показывает, какая доля дохода уходит на бонусы. Если >20% — сигнал для пересмотра бонусной политики. Metrics Dictionary

Buddy

Опытный сотрудник, назначаемый новичку на период onboarding (обычно 1 месяц). Помогает с контекстом, отвечает на вопросы, ревьюит первые PR. Onboarding

CAC (Customer Acquisition Cost)

Стоимость привлечения одного платящего клиента. Total Marketing Spend / Number of FTDs. Ключевая метрика unit economics. Metrics Dictionary

CDC (Change Data Capture)

Технология захвата изменений из production БД в реальном времени. В проекте: Debezium читает WAL PostgreSQL через Kafka Connect. Минимальная нагрузка на prod. Data Architecture

Census

Инструмент Reverse ETL — синхронизирует данные из DWH обратно в операционные системы (CRM, рекламные платформы). Use case: churn score → CRM → персональный бонус. Data Architecture

Churn Rate

Доля игроков, прекративших активность за период. Обычно: нет ставок 30+ дней = churned. Complement к retention. Metrics Dictionary

ClickHouse

Колоночная СУБД для аналитических запросов. Быстрые агрегации на больших объёмах. Primary DWH в проекте. Self-hosted, популярен в CIS/iGaming. Data Architecture

Cohort Analysis

Группировка пользователей по дате первого действия (регистрация, FTD) и отслеживание поведения когорты во времени. Основа для retention heatmap и LTV-прогнозов. Dashboards

Confidence Interval (CI)

Диапазон значений, в который с заданной вероятностью (обычно 95%) попадает истинное значение параметра. Используется в отчётах A/B-тестов для оценки effect size. A/B Testing

Conversion

Переход пользователя на следующий этап воронки. В iGaming ключевые: Visit→Registration, Registration→FTD, FTD→Repeat Deposit. Metrics Dictionary

CPA (Cost Per Acquisition)

Стоимость привлечения одного целевого действия. В iGaming обычно = CPD (Cost Per Deposit, стоимость за FTD). Metrics Dictionary

CRM (Customer Relationship Management)

Система управления жизненным циклом игрока: сегментация, коммуникации, бонусы, retention campaigns. Источник данных для analytics и потребитель ML-скоров через Reverse ETL. Data Architecture

Cross-validation

Техника оценки ML-модели: данные разбиваются на K фолдов, модель обучается на K-1 и проверяется на оставшемся. Снижает риск overfitting. MLOps

DAG (Directed Acyclic Graph)

Направленный ациклический граф — структура пайплайна в Airflow. Определяет последовательность задач и зависимости между ними. Data Architecture

Data Catalog

Централизованный реестр всех datasets: описания таблиц, ownership, lineage, tags, popularity. В проекте: DataHub. Data Governance

Data Dictionary

Стандартизированные определения бизнес-терминов (Active Player, FTD, GGR, NGR и т.д.). Утверждается на Governance Council. Изменения через формальный процесс. Data Governance

Data Drift

Изменение распределения входных данных ML-модели по сравнению с обучающей выборкой. Может привести к деградации модели. Мониторится через KS-test. MLOps

Data Governance

Совокупность практик управления данными: ownership, quality, access control, lifecycle, catalog. Обеспечивает доверие к данным. Data Governance

Data Lake

Хранилище сырых данных в исходном формате. В проекте: GCS (Google Cloud Storage) для raw / cold данных в формате Parquet. Data Architecture

Data Lineage

Визуализация пути данных от источника до потребителя. Показывает, откуда данные пришли, как трансформировались и куда попали. Data Lineage

Data Mesh

Архитектурный подход: децентрализация ownership данных по доменам. Каждый домен владеет и обслуживает свои data products. Evaluation запланирован на Q4. Roadmap

Data Owner

Бизнес-руководитель, ответственный за данные домена. Принимает решения о доступе, качестве, retention. Пример: Head of Product — owner betting data. Data Governance

Data Quality (DQ)

Измерение качества данных по 5 измерениям: completeness, accuracy, timeliness, consistency, uniqueness. Автоматизируется через dbt tests и Great Expectations. Data Governance

Data Steward

Технический ответственный за качество конкретного dataset (обычно аналитик или DE). Проверяет freshness, DQ scores, документацию. Data Governance

DataHub

Open-source data catalog (от LinkedIn). Хранит метаданные: описания таблиц, lineage, ownership, tags, DQ scores. Альтернативы: Atlan, Alation. Data Architecture

dbt (data build tool)

Инструмент трансформации данных (T в ELT). SQL-модели в три слоя: staging → intermediate → marts. Включает тестирование, документацию, lineage. Data Architecture

Debezium

Open-source CDC-платформа. Читает transaction log (WAL) из PostgreSQL и стримит изменения в Kafka. Минимальная нагрузка на production DB. Data Architecture

DWH (Data Warehouse)

Централизованное хранилище структурированных данных, оптимизированное для аналитических запросов. В проекте: ClickHouse. Data Architecture

ELT / ETL

Extract-Load-Transform (ELT) vs Extract-Transform-Load (ETL). В modern data stack используется ELT: данные

сначала загружаются в DWH «как есть», потом трансформируются (dbt). Data Architecture

ERD (Entity-Relationship Diagram)

Диаграмма связей между сущностями (таблицами). В проекте: mermaid.js erDiagram с 9 core entities. Data Model

Event Taxonomy

Систематика именования событий: {domain}_{object}_{action}. Стандарт для tracking plan. Пример: player_bet_placed, session_page_viewed. Event Taxonomy

Feast

Open-source Feature Store. Хранит, версионирует и сервирует фичи для ML-моделей. Пример: player_avg_bet_7d. Альтернатива: Tecton. MLOps

Feature Store

Централизованное хранилище ML-фичей. Обеспечивает consistency между training и serving, переиспользование фичей между моделями. MLOps

FinOps

Практика управления затратами на cloud-инфраструктуру и data-платформу. Оптимизация: партиционирование, TTL, reserved instances, query review. FinOps

FPR (False Positive Rate)

Доля ложных срабатываний. В fraud detection: легитимная транзакция ошибочно помечена как фрод. FPR < 3% — целевой порог. MLOps

FTD (First-Time Depositor)

Игрок, впервые внёсший депозит. Ключевой этап воронки. FTD Count — одна из главных метрик acquisition. Metrics Dictionary

GA4 (Google Analytics 4)

Платформа веб-аналитики от Google. Используется для маркетинговой атрибуции и web-аналитики. В проекте — в связке с GTM. Data Architecture

GCS (Google Cloud Storage)

Объектное хранилище Google Cloud. Используется как Data Lake для сырых данных и cold-архивов в формате Parquet. Data Architecture

GGR (Gross Gaming Revenue)

Валовой игровой доход. Сумма всех ставок минус сумма всех выплат: Bets - Payouts. Основная top-line метрика. Metrics Dictionary

Grafana

Платформа мониторинга и визуализации. В проекте: мониторинг инфраструктуры (ClickHouse, Airflow), DQ dashboards, алерты. DataOps

Great Expectations

Open-source фреймворк для валидации данных. Комплексные проверки DQ: cross-table consistency, distribution checks, custom validations. Дополняет dbt tests. Data Architecture

GTM (Google Tag Manager)

Система управления тегами на сайте. Позволяет маркетингу добавлять/изменять tracking без участия разработчиков. Server-side GTM для конфиденциальности. Data Architecture

Guardrail Metric

Защитная метрика в A/B-тесте. Не должна ухудшиться при внедрении изменения. Пример: тестируем новую форму депозита — guardrail: 24h deposit failure rate. A/B Testing

HADI Cycle

Фреймворк для экспериментов: Hypothesis → Action → Data → Insight, затем цикл повторяется. Основа процесса A/B-тестирования. A/B Testing

Hold %

Процент от ставок, который оператор оставляет себе. GGR / Turnover * 100%. В казино (slots) обычно 3-5%, в sports — 5-8%. Metrics Dictionary

Hypothesis

Формализованное предположение для A/B-теста. Формат: «Если [изменение], то [метрика] [направление] на [MDE], потому что [рациональ]». A/B Testing

ICE / RICE

Фреймворки приоритизации. ICE: Impact × Confidence × Ease. RICE: Reach × Impact × Confidence / Effort. Используются для ранжирования гипотез и задач в бэклоге. A/B Testing , Management

Incident

Событие, нарушающее SLA или нормальное функционирование данных. Классифицируется по severity: P1 (critical) → P2 (high) → P3 (medium). Incident Response

Kafka (Apache Kafka)

Распределённая платформа потоковой обработки данных. В проекте: real-time события (ставки, депозиты, сессии). Миллионы сообщений в секунду, multiple consumers. Data Architecture

KPI (Key Performance Indicator)

Ключевой показатель эффективности. Top-level KPIs Fantasy iGaming: NGR, Active Players, LTV:CAC, Retention. Metrics Dictionary

KYC (Know Your Customer)

Процедура верификации личности игрока. Обязательна по лицензии. Статусы: pending → verified → rejected. Влияет на доступ к выводу средств. Data Model

Lakehouse

Архитектура, объединяющая Data Lake (raw / cheap storage) и Data Warehouse (structured / fast queries). В проекте: ClickHouse + GCS Parquet — гибридный подход. Data Architecture

LightGBM

Gradient boosting фреймворк от Microsoft. Быстрый, эффективный на табличных данных. В проекте: алгоритм для LTV, Churn и Fraud моделей. MLOps

LTV (Lifetime Value)

Прогнозируемый суммарный NGR от игрока за всё время жизни (или 12 месяцев). Ключевая метрика unit economics. LTV > CAC — бизнес жизнеспособен. Metrics Dictionary

LTV:CAC Ratio

Отношение LTV к CAC. Показывает окупаемость привлечения. Benchmark: >3x — отлично, <1.5x — убыточно. Metrics Dictionary

MAE (Mean Absolute Error)

Средняя абсолютная ошибка прогноза. В проекте: MAE LTV-модели = $42.3 — в среднем прогноз отличается от реальности на $42. MLOps

MAPE (Mean Absolute Percentage Error)

Средняя абсолютная процентная ошибка. MAE в процентах от фактического значения. Целевой MAPE LTV-модели: <20%. MLOps

Mart (Data Mart)

Финальный слой dbt-моделей. BI/DS-ready таблицы: mart_daily_kpi, mart_player_lifetime, mart_cohort_analysis. Потребители: дашборды, отчёты, модели. Data Model

Materialized View

Предвычисленная агрегация, обновляемая при вставке данных. Ускоряет запросы в 10-50x. В ClickHouse — SummingMergeTree / AggregatingMergeTree. FinOps

MAU / DAU / WAU

Monthly / Daily / Weekly Active Users. Количество уникальных активных игроков за период. MAU Fantasy iGaming: ~500K. Metrics Dictionary

MDE (Minimum Detectable Effect)

Минимальный эффект, который A/B-тест способен обнаружить при заданном sample size и power. Чем меньше MDE, тем больше нужен sample. A/B Testing

Metabase

Open-source BI-платформа. Primary инструмент визуализации в проекте. Self-service: бизнес-пользователи сами строят запросы и дашборды. Data Architecture

MLflow

Open-source платформа для ML lifecycle: tracking экспериментов, model registry, артефакты. Альтернатива: Weights & Biases. MLOps

MLOps

Практики операционализации ML: CI/CD для моделей, мониторинг, retraining, feature store, model registry. DevOps для Machine Learning. MLOps

Model Drift

Деградация производительности ML-модели со временем из-за изменений в данных или бизнесе. Мониторится через PSI (Population Stability Index). MLOps

Model Registry

Централизованное хранилище версий ML-моделей: staging → production → archived. Процесс промоушена через review Lead DS и ML Engineer. MLOps

NGR (Net Gaming Revenue)

Чистый игровой доход — то, что бизнес реально оставляет себе. GGR - Bonus Cost - Provider Fees - Payment Fees - Taxes. Главная финансовая метрика. Metrics Dictionary

OKR (Objectives and Key Results)

Фреймворк целеполагания: Objective (качественная цель) + 3-5 Key Results (измеримые результаты). Квартальный цикл. Management

On-call

Дежурство DE-инженера (ротация по неделям). On-call реагирует на алерты, дебажит failed DAGs, эскалирует P1 инциденты. DataOps

Overfitting

Переобучение ML-модели: высокая точность на train-данных, низкая на новых. Борьба: cross-validation, regularization, early stopping. MLOps

P-value

Вероятность получить наблюдаемый (или более экстремальный) результат при условии, что нулевая гипотеза верна. $p < 0.05$ — стандартный порог статистической значимости. A/B Testing

Parquet

Колоночный формат хранения данных. Эффективная компрессия, быстрое чтение отдельных колонок. Используется в Data Lake (GCS) для архивных данных. Data Architecture

Partitioning

Разбиение таблицы на физические части (обычно по дате). Запросы с фильтром по дате читают только

нужные партиции. Ключевая оптимизация в ClickHouse. FinOps

Payback Period

Время окупаемости затрат на привлечение игрока. CAC / (Monthly NGR per player). Benchmark: <6 месяцев — здоровый бизнес. Metrics Dictionary

PII (Personally Identifiable Information)

Персональные данные: email, телефон, документы, IP. Доступ ограничен (RBAC), маскируется для non-compliance ролей. GDPR: удаление по запросу за 30 дней. Data Governance

Post-mortem

Документ-разбор инцидента без поиска виноватых. Содержит: timeline, root cause, что сработало, что нет, action items с дедлайнами. Incident Response

Power (Statistical Power)

Вероятность обнаружить реальный эффект в A/B-тесте (если он существует). Стандарт: 80%. Power = 1 - P(Type II Error). A/B Testing

Precision

Доля верно определённых положительных случаев среди всех, которые модель назвала положительными. TP / (TP + FP). Важна в fraud detection (минимизация false positives). MLOps

PSI (Population Stability Index)

Метрика стабильности распределения данных. Используется для мониторинга model drift. PSI > 0.2 — значительный сдвиг, нужен retrain. MLOps

RACI

Матрица ответственности: Responsible (делает), Accountable (отвечает), Consulted (консультирует), Informed (информируется). Определена для 7 ключевых процессов. Org Structure

RBAC (Role-Based Access Control)

Управление доступом на основе ролей. Матрица: роль × домен данных → уровень доступа (full / read / masked / no). Data Governance

Recall

Доля верно найденных положительных случаев среди всех реально положительных. TP / (TP + FN). Важна в churn prediction (не пропустить churning player). MLOps

Retention

Доля пользователей, вернувшихся через N дней после первого действия. D1/D7/D30 — стандартные окна. Визуализируется cohort heatmap. Metrics Dictionary

Reverse ETL

Обратная синхронизация: данные из DWH → операционные системы (CRM, Ad platforms). Пример: churn score из ClickHouse → CRM → персонализированный бонус. Data Architecture

ROAS (Return on Ad Spend)

Возврат на рекламные инвестиции. Revenue / Ad Spend. ROAS >3x — хороший показатель для iGaming. Metrics Dictionary

Row-level Security (RLS)

Ограничение видимости строк таблицы в зависимости от роли пользователя. Пример: аналитик CIS видит только данные geo = 'CIS'. Data Governance

RTP (Return to Player)

Процент от ставок, возвращаемый игрокам в виде выигрышей (теоретический). Для слотов: 94-97%. Actual RTP мониторится vs theoretical (отклонение ±2pp — alert). Metrics Dictionary

Runbook

Пошаговая инструкция для on-call инженера: что проверить, как починить типовой инцидент. 4 runbook в проекте: DAG failure, query timeout, source delay, DQ failure. DataOps

Sample Size

Минимальное количество наблюдений для статистически значимого результата A/B-теста. Зависит от baseline, MDE, power и significance level. A/B Testing

Semantic Layer

Слой абстракции между DWH и конечным пользователем. Стандартные определения метрик и dimensions, доступные через BI без SQL. Деплоится в Q2. Roadmap

SLA (Service Level Agreement)

Соглашение об уровне обслуживания. Матрица: кто → кому → что → целевой показатель → эскалация. Пример: DE → Analytics: данные к 07:00 UTC. SLA

Snowflake

Cloud DWH с разделением compute/storage. Западный стандарт. Альтернатива ClickHouse. Плюс: serverless, auto-scaling. Минус: дороже при больших объёмах. Data Architecture

Staging (stg_)

Первый слой dbt-моделей. 1:1 с source: type casting, dedup, cleanup. Без бизнес-логики. Пример: stg_betting__bets. Data Model

Statistical Significance

Порог, при котором результат A/B-теста считается не случайным. Стандарт: $p < 0.05$ (95% confidence level). A/B Testing

Taxonomy

Систематика классификации и именования (событий, метрик, данных). В проекте: Event Taxonomy — стандарт именования tracking events. Event Taxonomy

Timeliness

Одно из 5 измерений Data Quality: данные доступны вовремя. Измеряется как «mart обновлён к 07:00 UTC». Data Governance

Tracking Plan

Таблица всех отслеживаемых событий: название, триггер, параметры, источник (frontend/backend), owner, статус. 15 событий в проекте. Event Taxonomy

TTL (Time-to-Live)

Политика автоматического перемещения или удаления данных по возрасту. В ClickHouse: hot (3 мес, NVMe) → cold (12 мес, HDD) → archive (5 лет, GCS). FinOps

Turnover (Handle)

Общая сумма всех ставок за период. Самая верхняя метрика revenue: из неё вычитаются выплаты (= GGR), затем затраты (= NGR). Metrics Dictionary

Type I / Type II Error

Type I (false positive): видим эффект, которого нет (p-value ошибка). Type II (false negative): не видим реальный эффект (недостаточный power). A/B Testing

Unit Economics

Экономика единицы продукта (одного игрока): LTV, CAC, LTV:CAC, Payback Period. Показывает, окупается ли привлечение на уровне когорты. Metrics Dictionary

Wagering (Wagering Requirement)

Условие отыгрыша бонуса: сколько раз нужно поставить сумму бонуса, прежде чем можно вывести выигрыш. Пример: бонус $100 с вейджером x30 = нужно поставить $3000. Data Model

Whale

VIP-игрок с аномально высоким объёмом ставок и депозитов. Обычно top 1-2% игроков генерируют 20-30% GGR. Требуют персонального подхода и мониторинга. Data Governance

Не нашли термин? Предложите добавить через

.

О проекте и авторе

Зачем этот проект, кто за ним стоит и как присоединиться.

О проекте

Однажды я вернулся с собеседования на позицию директора по аналитике в крупной iGaming-компании. На подготовку к интервью ушло несколько дней — нужно было освежить понятийный аппарат, собрать кейсы, разложить по полочкам стек, governance, ML lifecycle, управленческие практики.

И я подумал: а что если собрать всё это в одном месте? Не абстрактную статью «что такое modern data stack», а конкретный, живой пример — как выглядит аналитическая функция. И описать ее целиком. Со стеком, командой, метриками, процессами, дашбордами.

Так появился Fantasy iGaming Data Department .

Для кого

- Data-лиды и директора — как референс при построении или реструктуризации data-функции
- Аналитики и DS — чтобы увидеть полную картину: не только свой стрим, но и как всё связано
- Data Engineers — архитектура, пайплайны, DQ, on-call — в контексте реальной компании
- Те, кто готовится к собеседованию — structured reference по всем темам data-функции
- Основатели и CTO — понять, что такое «data team» и сколько это стоит

> *WARNING: Disclaimer. Это не best practice и не консалтинг. Это идеализированная, но реалистичная картина — стартовая точка для обсуждения. У каждой компании свой контекст, и правильный ответ зависит от масштаба, рынка и команды.*

Об авторе

Константин Гупалов

Head of Analytics / Data Strategy Leader

12+ лет в data & analytics. Строил data-функции с нуля и масштабировал. Работал на стыке бизнес-стратегии и технической архитектуры — от определения KPI с C-level до проектирования DWH.

Ключевые домены: iGaming (Parimatch, SOFTSWISS), AdTech (Admixer — Google Marketing Platform), SaaS (Nuwber), Enterprise consulting (EPAM), GameDev (Wargaming).

Core strengths: масштабирование аналитических команд, data governance, качество данных, маркетинговая аналитика, юнит экономика, A/B-тестирование, культура экспериментов.

Полезные материалы

Книги и гайды от автора — в свободном доступе.

A/B Testing 101: The Anatomy of Evidence

Гайд по A/B-тестированию: от формулировки гипотезы до интерпретации результатов. Статистика, sample size, типовые ошибки.

SQL 101: Рецепты продуктового аналитика

Практическое руководство по SQL для аналитиков: от базовых запросов до оконных функций и когортного анализа.

Fantasy iGaming Data Department — Playbook (PDF)

Полная офлайн-версия справочника. 100+ страниц, все 19 разделов. PDF сгенерирован автоматически — возможны незначительные отличия в вёрстке от веб-версии.

Contributing

Проект open-source. Буду рад обратной связи и контрибуции.

GitHub Issues — предложения и баги

Нашли ошибку в формуле, неточность в SQL, опечатку? Хотите предложить новый раздел или термин в глоссарий?

- Откройте Issue в репозитории проекта
- Опишите: что не так / что предлагаете
- Укажите страницу и секцию (если это правка)

Pull Requests — контрибуция кодом

Хотите добавить контент или исправить что-то самостоятельно:

- Fork → branch → PR
- Контент на русском, code/classes на английском
- Следуйте паттернам компонентов (accordion, card, code-block)
- Все цвета — из CSS-переменных, без hardcoded значений
- Проверьте: навигация, мобильная версия (375px), аккордеоны

Обратная связь

Для вопросов, идей или просто сказать «спасибо» — пишите в LinkedIn:

linkedin.com/in/konstantin-gupalov

Changelog

- **v1.0 — Апрель 2026**
  Первый публичный релиз. 19 страниц: архитектура, команда, модель данных, метрики, governance, SLA, DataOps, MLOps, lineage, incident response, дашборды, A/B testing, management, onboarding, FinOps, roadmap, glossary, about.